




UNIVERSITÀ DEGLI STUDI DI PADOVA
DIPARTIMENTO DI SCIENZE STATISTICHE

Statistica per l'Economia e l'Impresa

Analisi del digital divide generazionale: un approccio di machine learning all'evoluzione dell'uso di Internet per età

Relatore: Prof. Bruno Arpino

Candidato: Luca Alberti

Matricola: 2051876

Anno Accademico: 2024–2025

Indice

Ringraziamenti	1
Abstract	2
1 Introduzione	4
1.1 Origini di Internet	4
1.1.1 L'arrivo di Internet in Italia	5
1.2 Contesto e motivazioni della ricerca	5
1.2.1 Livelli del digital divide: primo, secondo e terzo	5
1.3 Il digital divide in Italia: primo e secondo livello	6
1.3.1 Primo livello in Italia (accesso e infrastrutture)	7
1.3.2 Secondo livello in Italia (competenze e modalità d'uso)	7
1.4 Dataset	7
1.5 Struttura dell'elaborato	8
2 Contesto teorico	9
3 Dati e metodologia	11
3.1 Fonte dei dati	11
3.2 Limiti di comparabilità dei dati ISTAT	11
3.3 Pulizia e armonizzazione dei dati	12
3.4 Costruzione degli indici di utilizzo di Internet	13
3.4.1 Selezione delle variabili e raggruppamento tematico	13
3.4.2 Risultati dell'analisi fattoriale e pesi normalizzati	15
3.5 Aggregazione delle variabili e costruzione degli indici	18
3.5.1 Passi di calcolo	18
3.5.2 Formule esplicite	19

3.5.3	Sintesi di secondo livello: dall'uso per dominio all'uso complessivo	20
3.6	Analisi fattoriale, scelta della dimensionalità e verifica dei pesi	22
3.6.1	Dati e metodo	22
3.6.2	Scelta del numero di fattori	23
3.6.3	Struttura a due fattori: osservazioni qualitative . .	23
3.6.4	Dai loading ai pesi per variabile	23
3.6.5	Confronto con pesi esterni e misura dello scostamento	24
3.6.6	Conclusioni operative	25
4	Analisi descrittiva	26
5	Cluster Analysis	29
5.1	Cluster analysis: inquadramento teorico	29
5.1.1	Indice di silhouette	29
5.2	Cluster analysis sugli indici	30
5.2.1	Risultati statistici della soluzione a $k = 4$	32
5.2.2	Interpretazione dei cluster	33
5.2.3	Profili sociali nella soluzione a quattro cluster . . .	34
5.3	Conclusioni	36
6	Interazioni e importanza delle variabili nei modelli Random Forest	37
6.1	Cenni sul Random Forest e sulle metriche usate	37
6.2	Setup dei modelli	39
6.3	Importanza marginale	39
6.4	Selezione delle coppie per i PDP 2D	41
6.5	Lettura dei grafici di <i>minimal depth</i> e scelta delle coppie .	41
6.6	PDP 2D: evidenze visive delle non-additività	44
6.7	Sintesi interpretativa	46
7	Regressioni logistiche su idxFUN e idxSERIO	48
7.1	Impostazione	48
7.1.1	Fractional logit: modello, outcome e odds ratio . .	48
7.2	Variabili considerate	49
7.3	Bontà di adattamento	51

7.4	Risultati per idxFUN	52
7.5	Risultati per idxSERIO	53
7.6	Lettura trasversale e implicazioni	54
7.7	Conclusioni	62
8	Conclusioni e sviluppi futuri	63
	Bibliografia	67

Ringraziamenti

Ai miei nonni, che mi hanno sempre incoraggiato a studiare.

Abstract

Questa tesi misura e interpreta l'uso di Internet in Italia attraverso i dati dell'indagine *Aspetti della vita quotidiana* (AVQ) di ISTAT. A partire da item dicotomici, vengono costruiti indici di dominio (informativo, social, intrattenimento, sanitario, finanziario) mediante analisi fattoriale su matrice poliorica con pesi rinormalizzati. Gli indici sono sintetizzati in due dimensioni latenti: un uso *ludico* (`idxFUN`) e uno *utilitaristico* (`idxSERIO`), combinati nell'indice complessivo (`idxTOT`) con pesi proporzionali alla varianza spiegata. L'analisi è condotta sui soli individui che hanno utilizzato Internet negli ultimi tre mesi, per focalizzare lo studio sul *secondary digital divide*.

I risultati mostrano livelli mediamente più elevati nell'ambito informativo, seguiti da social ed intrattenimento, mentre sanità e finanza risultano meno diffusi. La segmentazione k-means a quattro gruppi identifica profili interpretabili: utilizzatori marginali, “info-only”, social & info, e *heavy multipurpose*. Modelli Random Forest, profili PDP e regressioni logistiche confermano che l'età è il principale driver, con interazioni rilevanti con istruzione, condizione occupazionale e territorio; le differenze di genere e cittadinanza sono contenute. Emerge un gradiente geografico favorevole a Nord e Centro rispetto a Sud e Isole, soprattutto per l'uso “serio”.

Le implicazioni operative includono: programmi di alfabetizzazione mirati alle fasce anziane su compiti concreti (PA online, banking, servizi sanitari online); rafforzamento dei servizi digitali e della formazione nei contesti locali più svantaggiati; principi di design inclusivo per trasformare utenti marginali in *multipurpose*. Tra i limiti si segnalano disomogeneità di questionario tra annualità, finestre temporali non omogenee di alcuni item e la scelta interpretativa dei cut-off nei carichi fattoriali. Per future rilevazioni si suggeriscono maggiore armonizzazione longitudinale, misure di in-

tensità/competenza oltre la dicotomia uso/non uso e possibili integrazioni con fonti amministrative per validazione esterna degli indici.

Capitolo 1

Introduzione

1.1 Origini di Internet

Il 29 ottobre 1969 un computer dell'Università della California a Los Angeles inviò le prime due lettere (“LO”) ad una postazione dello Stanford Research Institute, inaugurando il funzionamento di **ARPANET**, la rete sperimentale del Dipartimento della Difesa USA (Kleinrock 2019). Nei primi anni la utilizzavano soprattutto militari e gruppi universitari di ricerca; attraverso la rete potevano scambiarsi messaggi, condividere file e sfruttare a distanza la potenza di calcolo di altri centri. Negli anni Settanta prese forma il principio di suddividere i dati in pacchetti instradati autonomamente, e il 1^o gennaio 1983 l'intera rete adottò il nuovo linguaggio comune **TCP/IP**, data ricordata come *flag-day* di Internet (**Internet Society s.d.**). Un ulteriore passo avvenne al CERN di Ginevra, dove Tim Berners-Lee ideò il **World Wide Web** (1989) e, il 6 agosto 1991, pubblicò il primo sito accessibile al pubblico (**CERN s.d.**). Grazie a questo sistema di pagine collegate, chi possedeva un personal computer con modem poteva, tramite un browser, aprire documenti, immagini e link con pochi comandi, trasformando la rete da strumento riservato a specialisti a luogo di studio, lavoro e vita quotidiana per un numero crescente di persone.

1.1.1 L'arrivo di Internet in Italia

Nel 1994 la piccola **Video On Line** rese possibile collegarsi da qualunque città italiana con una semplice chiamata urbana: l'utente installava il programma da dischetto, dava il comando "Connetti" anche solo da un PC con 4–8 MB di RAM e si ritrovava in rete attraverso un modem che trasmetteva poco più di 28 kbit/s. Per la prima volta, posta elettronica, pagine Web e forum testuali apparivano sullo schermo di casa, prerogativa fino ad allora riservata alle università (Wired 1996).

Sei anni dopo, l'accesso dial-up era dominato da **TIN.it**, ormai parte di Telecom Italia/Seat Pagine Gialle: grazie a tariffe senza canone e alle prime linee ADSL, milioni di famiglie potevano tenere aperto il browser tutto il giorno, caricare foto, chattare e fare acquisti online senza occupare il telefono; inoltre il sistema operativo Windows 95 rendeva l'esperienza più immediata, estendendo Internet dalle cerchie di appassionati al grande pubblico (Telecom Italia 2000). In breve, l'innovazione di VOL abbatté i costi d'ingresso, mentre TIN.it trasformò la rete in un servizio domestico continuo, alimentato da interfacce grafiche che richiedevano pochi clic e nessuna competenza specialistica, aprendo la strada all'uso quotidiano del Web in Italia.

1.2 Contesto e motivazioni della ricerca

A circa trent'anni dall'arrivo di internet in Italia, la rete pervade ogni sfera della vita sociale ed economica; eppure l'accesso, la frequenza e la qualità d'uso non sono omogenee: differenze generazionali e socio-culturali alimentano un **digital divide di seconda generazione**, in cui conta non soltanto essere connessi ma *come* si utilizza la rete. Misurare tali disuguaglianze è cruciale per guidare politiche di inclusione digitale e investimenti infrastrutturali.

1.2.1 Livelli del digital divide: primo, secondo e terzo

Il concetto di *digital divide* descrive le disuguaglianze nell'accesso e nell'uso delle tecnologie dell'informazione e della comunicazione. In letteratura si

distinguono tre livelli complementari:

- **Primo livello (primal digital divide):** riguarda l'**accesso materiale** a Internet e ai dispositivi (disponibilità di connessione, qualità/velocità della rete, copertura territoriale, costo dei servizi, possesso di dispositivi adeguati). Si tratta di un divario prevalentemente infrastrutturale ed economico.
- **Secondo livello (secondary digital divide):** dipende dalle **competenze** e dalle **modalità d'uso**. A parità di accesso, gli individui possono differire per alfabetizzazione digitale, autonomia operativa, consapevolezza, sicurezza, varietà e frequenza delle attività online (es. servizi PA, lavoro/studio, utilizzo di servizi bancari/informativi/di intrattenimento).
- **Terzo livello (third digital divide):** riguarda le **ricadute e i benefici** ottenuti dall'uso del digitale (esiti occupazionali e di reddito, accesso a welfare/servizi, partecipazione civica, salute/benessere). Qui il focus è sul valore generato dall'uso, non solo sull'uso in sé.

I tre livelli sono gerarchici ma interdipendenti: senza accesso (primo livello) non si sviluppano competenze/usi (secondo livello), e senza usi efficaci difficilmente emergono benefici (terzo livello). La misurazione richiede quindi indicatori distinti per (i) accesso, (ii) competenze/usi, (iii) esiti, con letture condizionate (ad es. valutare il secondo livello *condizionato* all'accesso).

Nota operativa. Nel seguito, il secondo livello è misurato tramite indici compositi di uso (ad es. `idxFUN`, `idxSERIO`, `idxTOT`), mentre il primo livello è controllato con variabili di accesso (connessione, dispositivi). Il terzo livello non sarà trattato.

1.3 Il digital divide in Italia: primo e secondo livello

Il caso italiano presenta, in linea con altri paesi europei, divari **territoriali** (aree interne/rurali vs aree urbane), **generazionali** (anziani), e **socio-**

culturali (istruzione, condizione occupazionale) che si manifestano sia nel primo che nel secondo livello.

1.3.1 Primo livello in Italia (accesso e infrastrutture)

Il primo livello riflette differenze in:

- **Copertura e qualità della rete:** eterogeneità tra aree urbane/metropolitane e aree periferiche o a bassa densità; differenze nella disponibilità di connessioni ad alta velocità.
- **Costo/affordability e dotazioni:** impatto delle condizioni economiche familiari su abbonamenti e sostituzione/aggiornamento dei dispositivi.
- **Dotazione domestica e individuale:** numero e tipologia di dispositivi (PC, tablet, smartphone) e presenza di connessione domestica.

1.3.2 Secondo livello in Italia (competenze e modalità d'uso)

Il secondo livello si manifesta in:

- **Differenze per età e istruzione:** minore ampiezza/varietà d'uso tra anziani e tra individui con bassa scolarità; gap nelle attività complesse (PA online, banking, e-learning, lavoro da remoto).
- **Eterogeneità territoriale:** minore diversificazione d'uso in aree periferiche e in contesti con minore offerta di servizi digitali.
- **Differenziazione per condizione socio-occupazionale e nucleo familiare:** la partecipazione a lavoro/studio tendono ad aumentare l'attività online.

1.4 Dataset

Per analizzare il fenomeno, la tesi impiega i micro-dati dell'indagine annuale “**Aspetti della vita quotidiana – AVQ**” condotta dall'ISTAT, che

rileva un ampio spettro di attività online su circa 50'000 individui (ISTAT 2025) . L'obiettivo è costruire **indici compositi** dell'intensità d'uso di Internet e identificarne i principali determinanti sociodemografici.

1.5 Struttura dell'elaborato

1. **Dati e costruzione degli indici:** ricodifica dei dati e costruzione di indici di utilizzo.
2. **Metodi di analisi:** sintesi fattoriale degli indici settoriali e clustering (k-means) per individuare profili omogenei di utilizzatori. Random Forest e regressioni per quantificare l'importanza delle variabili socio-demografiche.
3. **Risultati:** Valutazione dei divari al variare delle caratteristiche socio-demografiche.
4. **Conclusioni e prospettive:** sintesi delle evidenze e proposte di estensione, fra cui l'integrazione con dati longitudinali.

In sintesi, il lavoro intende fornire una **misura articolata e confrontabile dell'utilizzo di Internet in Italia**, trasformando un insieme eterogeneo di variabili in strumenti utili a decisori pubblici e ricercatori impegnati a colmare il divario digitale.

Capitolo 2

Contesto teorico

L'analisi dei comportamenti sociali e digitali richiede strumenti statistici in grado di sintetizzare fenomeni complessi in indicatori facilmente interpretabili. In questo contesto, l'utilizzo di metodi multivariati riveste un ruolo centrale, permettendo di elaborare misure sintetiche e di esplorare relazioni tra più variabili contemporaneamente.

Uno degli strumenti più utilizzati a tale scopo è l'analisi multivariata, un insieme di tecniche statistiche che consente di analizzare più variabili simultaneamente, superando i limiti delle analisi univariate o bivariate. Le tecniche multivariate sono particolarmente efficaci quando si lavora con dati socio-economici, dove le variabili sono spesso correlate tra loro e contribuiscono congiuntamente a spiegare fenomeni complessi come l'uso di internet, l'accesso all'informazione o l'utilizzo di strumenti digitali.

Nel caso specifico di questa tesi, si è fatto uso di indici compositi, ottenuti a partire da una selezione di variabili del questionario AVQ (Aspetti della Vita Quotidiana). Gli indici utilizzati – idxFUN, idxSERIO, e idxTOT – sintetizzano diversi aspetti dell'uso di internet, rispettivamente in ambiti ludico-ricreativi, funzionali/istituzionali e in modo aggregato. Questi indici sono stati costruiti secondo criteri coerenti con la letteratura e con le specificità del dataset ISTAT.

Per l'analisi dei pattern d'uso sono state poi impiegate tre tecniche statistiche avanzate: Cluster Analysis, Random Forest e Regressione Logistica. Il Random Forest è un algoritmo di apprendimento automatico basato su insiemi di alberi decisionali, utile per la previsione e la classificazione, oltre che per valutare l'importanza delle variabili esplicative. La

sua robustezza lo rende particolarmente adatto a gestire dati complessi e non lineari.

La Cluster Analysis, invece, consente di identificare gruppi omogenei all'interno del dataset, basandosi sulle similarità tra osservazioni. Questa tecnica è stata usata per esplorare le tipologie di utilizzo della rete tra individui, cercando di individuare profili ricorrenti in base agli indici sintetici.

La regressione logistica, invece, permette di stimare la probabilità di appartenenza a una categoria in base a una o più variabili esplicative. Questa tecnica è stata utilizzata per analizzare l'effetto di caratteristiche socio-demografiche sull'utilizzo di Internet, con particolare attenzione al ruolo dell'età. Il modello consente di quantificare l'impatto di ciascun fattore sul digital divide. In questo modo, si individuano le variabili che condizionano maggiormente i comportamenti digitali.

Le tecniche descritte rappresentano strumenti fondamentali per comprendere i fenomeni sociali in chiave quantitativa, e costituiscono il cuore metodologico del lavoro svolto.

Capitolo 3

Dati e metodologia

3.1 Fonte dei dati

I dati utilizzati in questa tesi provengono dall'indagine ISTAT Aspetti della Vita Quotidiana (AVQ), che rileva ogni anno informazioni sulle condizioni di vita, i comportamenti e l'accesso ai servizi della popolazione italiana. In particolare, l'analisi si basa sulle rilevazioni relative agli anni 2021 e 2022, con un totale complessivo di circa 41.000 osservazioni individuali. Questi dati contengono variabili socio-demografiche, tra cui età, sesso, livello di istruzione, condizione occupazionale, cittadinanza e un insieme di domande relative all'utilizzo di internet.

3.2 Limiti di comparabilità dei dati ISTAT

Una delle principali **limitazioni nel rileggere in serie storica i dati ISTAT sull'uso di Internet** è che lo strumento di rilevazione cambia quasi di anno in anno a causa della continua evoluzione dell'oggetto di studio. Il questionario del 2012, ad esempio, chiedeva ancora se in famiglia si possedesse un “personal computer” o un “cellulare abilitato alla trasmissione di immagini e dati”, e misurava la navigazione soprattutto da desktop o portatile; appena il 28% circa degli utenti dichiarava di connettersi da un telefono mobile (smartphone compresi) e i focus erano il possesso dei dispositivi e l'accesso a banda larga. Dieci anni dopo, il modulo 2022 introduce voci del tutto nuove: distingue la connessione da smartphone, tablet,

smart-TV o assistenti vocali; misura quante persone pagano l'abbonamento a piattaforme di video o musica in streaming (la categoria «film o serie in streaming o download» è ormai più citata degli elettrodomestici fra gli acquisti online) e dedica un'intera sezione a servizi digitali come SPID, app della Pubblica Amministrazione e cloud personale. In pratica, **il baricentro delle domande si sposta dalla proprietà del mezzo** (PC, modem, CD o DVD acquistati) **alla fruizione di servizi in abbonamento** e a un uso prevalentemente *mobile*; questo rende difficile confrontare in modo diretto percentuali e indicatori lungo l'intero arco 2012-2022, perché ciò che viene misurato (dispositivi, piattaforme ed utilizzo) non è più lo stesso. Per i motivi sopra citati nasce la necessità di ricodificare le variabili e di lavorare su categorie aggregate più stabili. La forte discontinuità introdotta dai rapidi aggiornamenti del questionario ha costretto l'analisi a spostare l'attenzione sull'utilizzo **recente** di Internet. Di conseguenza non è stato possibile concentrare gli sforzi su una vera e propria lettura **longitudinale** del fenomeno.

3.3 Pulizia e armonizzazione dei dati

Uno degli aspetti fondamentali affrontati nel corso dell'analisi è stato il processo di uniformazione delle codifiche, necessario per garantire la coerenza tra i dati delle annualità 2021 e 2022. Pur mantenendo un significato concettuale analogo, alcune domande relative all'utilizzo di internet presentavano codifiche di risposta differenti tra le due edizioni dell'indagine. È stato pertanto necessario effettuare una riparametrizzazione manuale, ricodificando tutte le modalità di risposta in modo uniforme, al fine di ottenere variabili comparabili e consistenti. Tuttavia, si segnala che non è stato possibile estendere l'analisi a tutte le annualità disponibili dell'indagine AVQ, che ha avuto inizio nel 2012, a causa delle profonde modifiche strutturali apportate nel tempo alle domande sull'utilizzo di internet. Queste modifiche riflettono i rapidi cambiamenti intercorsi sia nella diffusione dei dispositivi di accesso (passaggio progressivo da computer a smartphone e tablet), sia nell'evoluzione delle piattaforme digitali utilizzate (emergere dei social media, servizi online, app mobili). Di conseguenza, il contenuto

delle domande, così come le opzioni di risposta, è variato sensibilmente nel tempo, rendendo non possibile la costruzione di indici aggregati validi per un'analisi longitudinale coerente su più anni.

3.4 Costruzione degli indici di utilizzo di Internet

Nota metodologica — Filtro dei rispondenti

Per costruire in modo coerente gli indici legati all'utilizzo di Internet, si è deciso di considerare esclusivamente i rispondenti che hanno dichiarato di aver usato Internet negli ultimi 3 mesi, in base alla variabile `INTTEMPO`. Poiché la quasi totalità (ad esclusione di `COSINT9A/B/C` e `PWEB`) dei quesiti utilizzati per la costruzione degli indici fanno esplicito riferimento all'utilizzo negli ultimi 3 mesi. Questo filtro consente di standardizzare l'analisi rispetto al **primal digital divide**, escludendo coloro che non hanno accesso regolare a Internet. In tal modo, gli indici riflettono esclusivamente le differenze nei modi di utilizzo (digital use divide), e non l'accesso stesso alla rete.

3.4.1 Selezione delle variabili e raggruppamento tematico

Per riassumere in modo compatto i diversi usi di Internet sono stati selezionati in totale 18 quesiti del questionario, successivamente accorpati in cinque aree tematiche (domini) concettualmente omogenee. Nelle sottosezioni che seguono sono riportati, per ciascun dominio, l'indice costruito e l'elenco completo delle relative domande.

Indice `idxint` — Intrattenimento

- **INTATT31** – «Negli ultimi 3 mesi ha letto o scaricato libri online o e-book?»
- **INTATT7BN** – «Negli ultimi 3 mesi ha guardato la televisione in streaming?»

- **INTATT30B** – «Negli ultimi 3 mesi ha guardato contenuti video da servizi di condivisione (es. YouTube)?»
- **INTATT30A** – «Negli ultimi 3 mesi ha guardato video on demand?»
- **INTATT28B** – «Negli ultimi 3 mesi ha giocato o scaricato giochi?»

Indice idxsal — Sanità

- **INTSAL3** – «Negli ultimi 3 mesi ha preso un appuntamento con un medico via Internet?»
- **INTATT14** – «Negli ultimi 3 mesi ha cercato informazioni sanitarie su Internet?»
- **INTFASC** – «Negli ultimi 3 mesi ha acceduto al fascicolo sanitario elettronico?»
- **INTALTSAL** – «Negli ultimi 3 mesi ha utilizzato altri servizi sanitari online?»

Indice idxfin — Finanza

- **INTATT11** – «Negli ultimi 3 mesi ha usato Internet per servizi bancari (home banking)?»
- **COSINT9a** – «Negli ultimi 12 mesi ha acquistato/venduto azioni, obbligazioni, fondi o altri servizi finanziari online (escluse e-mail)?»
- **COSINT9b** – «Negli ultimi 12 mesi ha acquistato o rinnovato polizze assicurative tramite Internet (escluse e-mail)?»
- **COSINT9c** – «Negli ultimi 12 mesi ha ottenuto un prestito/credito da banche o da altri fornitori di servizi finanziari online (escluse e-mail)?»

Indice idxinf — Informazione

- **PWEB** – «Si informa dei fatti della politica attraverso Internet?»
- **INTATT8** – «Negli ultimi 3 mesi ha usato internet per leggere giornali, informazioni o riviste online?»
- **INTATT16** – «Negli ultimi 3 mesi ha usato internet per cercare informazioni su merci o servizi?»

Indice idxsoc — Social / Condivisione

- **INCOMU6** – «Negli ultimi 3 mesi ha partecipato a social network (creato profilo, postato messaggi, ecc.)?»
- **INCOMU7** – «Negli ultimi 3 mesi ha usato internet per esprimere opinioni su temi sociali o politici (blog, social network, ecc.)?»

3.4.2 Risultati dell'analisi fattoriale e pesi normalizzati

Per la costruzione degli indici compositi è stata adottata l'analisi fattoriale basata sulla matrice di correlazioni policoriche, poichè nel nostro caso, le variabili utilizzate per la costruzione degli indici, sono di tipo dicotomico (utilizza/non utilizza un determinato servizio). L'impiego della classica matrice di correlazioni di Pearson non sarebbe quindi appropriato, poiché tale metodo presuppone variabili continue e normalmente distribuite. La scelta adottata consente di stimare in modo più accurato le associazioni tra variabili ordinali e dicotomiche. La correlazione policorica, infatti, si fonda sull'ipotesi che le categorie osservate siano il risultato della discretizzazione di variabili latenti continue distribuite normalmente: in questo modo è possibile cogliere relazioni latenti che la Pearson trascurerebbe. Questa scelta metodologica permette quindi di ottenere fattori più stabili e interpretabili, garantendo che gli indici costruiti riflettano in maniera coerente i diversi domini di utilizzo di Internet considerati (sanitario, intrattenimento, finanziario, informativo, social).

La prima colonna dei prospetti riporta il *loading* (carico fattoriale); la seconda colonna mostra il peso normalizzato, ottenuto dividendo il valore assoluto del loading per la somma dei loadings del dominio, così che la loro somma valga 1.

Indice `idxsal` — Sanità

Tabella 3.1: Carichi fattoriali e pesi normalizzati — dominio Sanità

Variabile	Loading	Peso norm. (0–1)
INTATT14	0.293	0.202
INTSAL3	0.446	0.308
INTFASC	0.320	0.221
INTALTSAL	0.391	0.270

Indice `idxint` — Intrattenimento

Tabella 3.2: Carichi fattoriali e pesi normalizzati — dominio Intrattenimento

Variabile	Loading	Peso norm. (0–1)
INTATT7BN	0.343	0.217
INTATT30A	0.471	0.298
INTATT30B	0.342	0.217
INTATT31	0.238	0.151
INTATT28B	0.185	0.117

Indice idxfin — Finanza

Tabella 3.3: Carichi fattoriali e pesi normalizzati — dominio Finanza

Variabile	Loading	Peso norm. (0–1)
INTATT11	0.466	0.255
COSINT9a	0.456	0.249
COSINT9b	0.493	0.270
COSINT9c	0.413	0.226

Indice idxinf — Informazione

Tabella 3.4: Carichi fattoriali e pesi normalizzati — dominio Informazione

Variabile	Loading	Peso norm. (0–1)
INTATT8	0.538	0.417
PWEB	0.454	0.352
INTATT16	0.299	0.231

Indice idxsoc — Social / Condivisione

Tabella 3.5: Carichi fattoriali e pesi normalizzati — dominio Social/Condivisione

Variabile	Loading	Peso norm. (0–1)
INCOMU6	0.597	0.500
INCOMU7	0.597	0.500

Si osserva che:

- **Sanità e Finanza** presentano distribuzioni di peso piuttosto equilibrate, sebbene in entrambi i domini emerga una variabile leggermente più rilevante (INTSAL3 per la Sanità e COSINT9b per la Finanza);
- Per l'indice di **Intrattenimento** l'attività di streaming on-demand (INTATT30A) risulta la componente principale, con un peso prossimo al 30%, seguita da altre variabili con contributi più contenuti;
- Nel dominio **Informazione** tutte le variabili mostrano un apporto consistente, con un'incidenza maggiore per INTATT8, ma senza squilibri marcati;
- Per l'indice **Social/Condivisione**, le due variabili considerate (INCOMU6 e INCOMU7) hanno lo stesso peso e contribuiscono in maniera identica alla formazione dell'indice, indicando un dominio estremamente bilanciato.

3.5 Aggregazione delle variabili e costruzione degli indici

Nel capitolo precedente sono stati presentati i pesi normalizzati w_j ottenuti mediante analisi fattoriale per ciascun dominio **sal**, **int**, **fin**, **inf** e **soc**. Qui descriviamo il calcolo operativo degli indici

$$\text{idxsal}, \text{idxint}, \text{idxfin}, \text{idxinf}, \text{idxsoc},$$

che verranno poi utilizzati nelle analisi successive.

3.5.1 Passi di calcolo

1. **Ricodifica 0–1 delle variabili binarie** Tutte le domande sono state trasformate in variabili dicotomiche $x_j \in \{0, 1\}$. In questo modo ogni risposta *affermativa* riguardo l'utilizzo vale 1, mentre la mancata fruizione dell'attività vale 0.

2. **Combinazione lineare pesata** Per ogni dominio d con insieme di variabili D_d l'indice grezzo si ottiene come

$$\text{idx}_d = \sum_{j \in D_d} w_j x_j, \quad \text{con} \quad \sum_{j \in D_d} w_j = 1.$$

Poiché i pesi normalizzati w_j sommano a 1, l'indice idx_d assume valori compresi nell'intervallo $[0, 1]$ e può essere interpretato come *quota di utilizzo* dell'insieme di attività coperte dal dominio.

3.5.2 Formule esplicite

Riportiamo di seguito le combinazioni lineari, con i pesi già discussi nel capitolo precedente.

$$\begin{aligned} \text{idxsal} = & 0.202 \text{INTATT14} + 0.308 \text{INTSAL3} \\ & + 0.221 \text{INTFASC} + 0.270 \text{INTALTSAL} \end{aligned}$$

$$\begin{aligned} \text{idxint} = & 0.217 \text{INTATT7BN} + 0.298 \text{INTATT30A} \\ & + 0.217 \text{INTATT30B} + 0.151 \text{INTATT31} + 0.117 \text{INTATT28B} \end{aligned}$$

$$\begin{aligned} \text{idxfin} = & 0.255 \text{INTATT11} + 0.249 \text{COSINT9a} \\ & + 0.270 \text{COSINT9b} + 0.226 \text{COSINT9c} \end{aligned}$$

$$\text{idxinf} = 0.417 \text{INTATT8} + 0.352 \text{PWEB} + 0.231 \text{INTATT16}$$

$$\text{idxsoc} = 0.5 \text{INCOMU6} + 0.5 \text{INCOMU7}$$

In tutti i casi l'indice può essere letto come "percentuale pesata di attività svolte" all'interno del dominio: un valore di 0.65 per idxfin , ad esempio, indica che l'intervistato compie mediamente il 65 % delle operazioni finanziarie considerate, tenendo conto del peso di ciascuna.

3.5.3 Sintesi di secondo livello: dall'uso per dominio all'uso complessivo

Prima di stimare il modello fattoriale è stata eseguita l'analisi delle componenti principali (PCA) sul set di indici `idxsal`, `idxint`, `idxfin`, `idxinf`, `idxsoc`. Dal tracciato delle PCA non è emerso un punto di flesso univoco, quindi il numero di componenti da trattenere è restato ambiguo; d'altra parte, con appena cinque variabili è verosimile che bastino pochi fattori. Per questo abbiamo comunque proceduto con un'Analisi Fattoriale (FA) estraendo al massimo quattro fattori, così da verificare empiricamente dove la varianza residua si stabilizza. Effettuando una **Analisi Fattoriale (FA) con rotazione varimax** testando da 1 a 4 fattori; la soluzione più parsimoniosa e interpretabile è quella a *due* fattori (`fat2`).




Figura 3.1: Quota di varianza residua al variare del numero di fattori.

Risultati della FA a due fattori Secondo l'output di `fat2$Vaccounted` la soluzione a due fattori spiega in totale il **41,0%** della varianza, con autovalori **1,03** e **1,02** e una ripartizione quasi equa della varianza spiegata (circa 51%–49%).

Interpretazione dei fattori

Tabella 3.6: Autovalori e varianza spiegata (AFA a due fattori)

Fattore	Autovalore	% Varianza	% Cumulata
1	1.03	21.0	21.0
2	1.02	20.0	41.0

Tabella 3.7: Loadings rotati sui fattori di secondo livello

Dominio	Fatt. 1 (FUN)	Fatt. 2 (SERIO)
Intrattenimento	0.76	-0.06
Social/Condiv.	0.16	-0.01
Sanità	-0.08	0.38
Finanza	-0.06	0.38
Informazione	0.05	0.25

- **Fattore 1 – Fun** (21 % della varianza totale, 51 % di quella comune) dipende soprattutto da *Intrattenimento* e, in misura minore, da *Social/Condivisione*; descrive quindi un uso ricreativo della rete.
- **Fattore 2 – Serio** (20 %) pesa principalmente gli usi *Sanitari*, *Finanziari* e di *Informazione*, cioè attività percepite come più “serie”.

Sia $I_{d,i}$ il punteggio dell'individuo i nel dominio d e $\tilde{w}_{d,f}$ il carico (in valore assoluto) del dominio d sul fattore f , rinormalizzato in modo che $\sum_d \tilde{w}_{d,f} = 1$ entro ciascun fattore. Inoltre, al fine di evitare sovrapposizioni, i carichi inferiori a 0,10 vengono azzerati.

$$\text{idxFUN}_i = 0.829 I_{\text{INT},i} + 0.171 I_{\text{SOC},i},$$

$$\text{idxSERIO}_i = 0.376 I_{\text{SAL},i} + 0.379 I_{\text{FIN},i} + 0.246 I_{\text{INF},i}.$$

Indice complessivo Poiché i due fattori contribuiscono in modo quasi identico alla varianza comune, l'indice totale è la media ponderata con pesi proporzionali alla percentuale di varianza spiegata dal singolo fattore (0.51–0.49):

$$\text{idxTOT}_i = 0.51 \text{idxFUN}_i + 0.49 \text{idxSERIO}_i.$$

Il risultato è un indicatore 0–1 che sintetizza in modo bilanciato sia gli usi “ricreativi” sia quelli “utilitaristici”, riflettendo l’importanza empirica quasi paritaria dei due fattori.

Limiti dell’aggregazione e lettura critica dei risultati Benché la sintesi a due fattori riduca la dimensionalità e renda più agile la lettura complessiva degli usi di Internet, i risultati non sono del tutto soddisfacenti. Anzitutto, la quota di varianza spiegata è pari al **41,0 %**, lasciando scoperto **circa il 59 %** della variabilità osservata: segno che alcuni pattern di comportamento rimangono intrappolati nei residui e non trovano adeguata rappresentazione nei soli *idxFUN* e *idxSERIO*. In secondo luogo, nel dominio *Social* i pesi risultano **perfettamente bilanciati** ($INCOMU6 = 0,5$; $INCOMU7 = 0,5$), il che segnala una limitata capacità discriminante di tale componente; inoltre, altri domini contribuiscono in misura marginale ai fattori estratti, con possibili effetti di sottorappresentazione. Per questi motivi, gli indici di secondo e terzo livello vanno utilizzati con cautela.

3.6 Analisi fattoriale, scelta della dimensionalità e verifica dei pesi

3.6.1 Dati e metodo

L’analisi fattoriale è stata condotta sulle 18 variabili *INTATT14*, *INTSAL3*, *INTFASC*, *INTALTSAL*, *INTATT7BN*, *INTATT30A*, *INTATT30B*, *INTATT31*, *INTATT28B*, *INTATT11*, *COSINT9a*, *COSINT9b*, *COSINT9c*, *INCOMU6*, *INCOMU7*, *PWEB*, *INTATT8*, *INTATT16*

La matrice di input è stata costruita con *correlazioni policoriche* e le soluzioni sono state ruotate con *varimax*, in coerenza con le aggregazioni già utilizzate per gli indici compositi (es. *idxsal*, *idfin*, ...).

Per guidare la scelta della dimensionalità sono stati stimati modelli con $m = 1, \dots, 5$ fattori e, per ciascuno, è stata calcolata la *proporzione di varianza residua* $1 - \text{Var.spiegata}(m)$. La Fig. 3.2 riporta il profilo risultante.




Figura 3.2: Proporzione di varianza residua in funzione del numero di fattori.

3.6.2 Scelta del numero di fattori

Dal grafico non emerge un “gomito” netto: la curva decresce in modo pressoché monotono e la sola ispezione visiva non consente una scelta univoca. Per questo è stato adottato anche il criterio di **Kaiser–Guttman** (autovalori > 1) calcolato sulla matrice di correlazioni: nella soluzione a tre fattori, solo i primi due presentano autovalori maggiori di 1, mentre il terzo è < 1 . In base a questo, e per **parsimonia** e **interpretabilità**, si adotta come specifica di riferimento la **soluzione a due fattori** (rotazione varimax).

3.6.3 Struttura a due fattori: osservazioni qualitative

La matrice dei pesi a due fattori evidenzia una ripartizione stabile delle variabili sui due assi latenti; fanno eccezione alcune voci dell’area *Informazione*, che ricadono nell’area dell’indice “serio” ma con magnitudini non elevate. Nel complesso, la struttura è coerente con le attese.

3.6.4 Dai loading ai pesi per variabile

Per costruire un *peso sintetico* per variabile coerente con la rilevanza relativa dei due fattori, si procede come segue.

(i) **Ponderazione per varianza spiegata.** Sia w_{ij} il coefficiente (peso) della variabile i sul fattore j nella soluzione a due fattori, e sia v_j la quota di varianza spiegata dal fattore j (“Proportion Explained”). Si costruiscono due pesi ponderati

$$\tilde{w}_{ij} = v_j w_{ij} \quad (j = 1, 2).$$

(ii) **Riduzione a un peso per variabile.** Per ogni variabile i si seleziona il contributo dominante come *massimo in valore assoluto* tra i due pesi ponderati:

$$w_i^{(\text{FA})} = \arg \max_{j \in \{1, 2\}} |\tilde{w}_{ij}|,$$

conservando il segno del contributo prevalente.

3.6.5 Confronto con pesi esterni e misura dello scostamento

I pesi $w_i^{(\text{FA})}$ sono stati confrontati con un sistema di pesi esterni $w_i^{(\text{ext})}$ ottenuto da aggregazioni precedentemente definite (combinazioni pesate di insiemi come *fa1 – fa5* tramite *wserio/wfun*). Dopo l’allineamento per nome variabile, lo **scarto** è definito come

$$e_i = w_i^{(\text{FA})} - w_i^{(\text{ext})}.$$

Per una valutazione sintetica della coerenza si considera la **media degli scarti assoluti** (MAE)

$$\text{MAE} = \frac{1}{p} \sum_{i=1}^p |e_i| \quad (p = 18).$$

Con gli aggiornamenti di calcolo (rotazione varimax; ponderazione per quota di varianza spiegata; scelta del contributo dominante), si ottiene

$$\text{MAE} \approx 0.0247.$$

Circa **9 variabili su 18** (cioè $\sim 50\%$) rientrano nella fascia di *errore contenuto* $|e_i| \leq 0.02$; per le restanti lo scostamento è comunque generalmente

moderato (≤ 0.03), con alcune eccezioni localizzate.

Scostamenti più rilevanti. Gli scarti (in valore assoluto) più alti si osservano per:

$$\begin{aligned} \text{PWEB} &\approx 0.078, & \text{INTATT8} &\approx 0.050, & \text{INTATT31} &\approx 0.043, \\ \text{INTATT16} &\approx 0.038, & \text{INTATT28B} &\approx 0.035, & \text{INTATT7BN} &\approx 0.031. \end{aligned}$$

Tali differenze riflettono aree in cui la ponderazione esterna assegna un peso relativamente maggiore/minore rispetto a quello implicato dalla struttura fattoriale a due dimensioni.

3.6.6 Conclusioni operative

- La scelta della **soluzione a due fattori** è supportata sia dal criterio degli autovalori (> 1) sia da considerazioni di parsimonia ed interpretabilità, in presenza di un profilo di varianza residua privo di “gomiti” marcati.
- Il confronto tra pesi mostra una **coerenza complessivamente buona**: lo scarto medio assoluto è contenuto (≈ 0.025). Le discrepanze maggiori sono circoscritte ad alcune voci specifiche (PWEB, elementi di Intrattenimento).
- La coerenza di *rotazione* è essenziale: l’intero confronto è condotto con varimax, la stessa scelta utilizzata nelle aggregazioni esterne, così da evitare differenze dovute unicamente alla rotazione.

Capitolo 4

Analisi descrittiva

Obiettivo Prima di qualunque inferenza, descriviamo la distribuzione dei tre indici compositi ($idxFUN$, $idxSERIO$, $idxTOT$) e la loro relazione con età, istruzione e genere. Le statistiche univariate sono riassunte nella Tabella 4.1, mentre la matrice di correlazione di Spearman è riportata nella Tabella 4.2.

Domini elementari Il dominio informativo ($idxinf$) mostra il valore medio più elevato, seguito dal social ($idxsoc$) e dall'intrattenimento ($idxint$). La componente sanitaria ($idxsal$) e quella finanziaria ($idxfin$) registrano punteggi inferiori. Questi domini alimentano gli indici aggregati.

Indici di secondo livello $idxFUN$ (uso “ludico”) è dominato da attività ricreative e sociali, con media pari a circa 0.464. $idxSERIO$ (uso “utilitaristico”), che riflette prevalentemente aspetti informativi, finanziari e sanitari, ha media inferiore (≈ 0.389). $idxTOT$, sintesi ponderata dei due precedenti (≈ 0.426).

Relazioni fra indici e variabili socio-demografiche La Tabella 4.2 mostra i coefficienti di Spearman. I risultati indicano:

- **Età (ETAMi):** l'uso “fun” decresce nettamente con l'età ($\rho = -0.47$), mentre quello “serio” mostra una correlazione debole ($\rho = -0.06$).

- **Istruzione (ISTRMi):** le correlazioni negative ($\rho = -0.20$ per *idxFUN*, $\rho = -0.35$ per *idxSERIO*) indicano un uso più frequente tra i più istruiti (ricordando la codifica inversa).
- **Condizione lavorativa (CONDMi):** ha una relazione negativa con entrambi gli indici, più forte con l'uso "serio" ($\rho = -0.23$), suggerendo una possibile barriera.
- **Area geografica (GEO):** l'associazione è debole ma suggerisce un maggiore utilizzo utilitaristico al Nord rispetto al Sud/Isole ($\rho = -0.17$).
- **Genere (SESSO):** effetti trascurabili ($|\rho| \leq 0.05$).
- **Cittadinanza (CITTMi):** effetti trascurabili anche in questo caso ($|\rho| \leq 0.03$).
- **Interrelazione tra indici:** la correlazione tra *idxFUN* e *idxSERIO* è moderata ($\rho = 0.41$), indicando parziale sovrapposizione tra le due tipologie di utilizzo.

Implicazioni *idxFUN* è strettamente legato all'età, mentre *idxSERIO* riflette prevalentemente fattori come istruzione e condizione economica. Genere e area geografica sembrano avere un'influenza minore. L'analisi giustifica la distinzione fra uso "fun" e "serio", oltre all'utilizzo di un indice sintetico complessivo. Si ricorda che **ETAMi** è una variabile categoriale con classi più dettagliate per le fasce giovanili, mentre **ISTRMi** assegna valori numerici arbitrari ai livelli di istruzione. Di conseguenza, i coefficienti di correlazione vanno interpretati con cautela, in quanto riflettono solo approssimativamente le relazioni tra le variabili.

Tabella 4.1: Statistiche di sintesi degli indici compositi

Indice	Media	SD	IC 95%
idxFUN	0.464	0.296	[0.461 - 0.467]
idxSERIO	0.389	0.221	[0.387 - 0.392]
idxTOT	0.426	0.218	[0.424 - 0.428]

Tabella 4.2: Matrice di correlazione di Spearman tra indici e variabili socio-demografiche

	CITTMi	CONDMi	GEO	ETAMi	ISTRMi	SESSO	idxFUN	idxSERIO
CITTMi	1.000	-0.023	-0.073	-0.060	0.020	0.044	-0.009	-0.021
CONDMi	-0.023	1.000	0.059	0.197	0.266	0.133	-0.120	-0.229
GEO	-0.073	0.059	1.000	-0.041	-0.014	-0.023	-0.005	-0.173
ETAMi	-0.060	0.197	-0.041	1.000	0.119	-0.013	-0.466	-0.056
ISTRMi	0.020	0.266	-0.014	0.119	1.000	-0.080	-0.195	-0.349
SESSO	0.044	0.133	-0.023	-0.013	-0.080	1.000	-0.042	0.001
idxFUN	-0.009	-0.120	-0.005	-0.466	-0.195	-0.042	1.000	0.409
idxSERIO	-0.021	-0.229	-0.173	-0.056	-0.349	0.001	0.409	1.000

Capitolo 5

Cluster Analysis

5.1 Cluster analysis: inquadramento teorico

La *cluster analysis* è una tecnica di statistica multivariata utilizzata per suddividere un insieme di unità statistiche in gruppi (*cluster*) omogenei al loro interno ed eterogenei tra loro. A differenza di altri metodi di classificazione, la cluster analysis è una tecnica *non supervisionata*: i gruppi non sono conosciuti a priori, ma emergono dai dati stessi in base alle distanze o similarità tra le osservazioni.

L'obiettivo principale è quindi quello di individuare strutture latenti nei dati, ottenendo una segmentazione che permetta di interpretare i diversi comportamenti o profili presenti nella popolazione. Nel contesto di questa analisi, i cluster sono costruiti a partire dai cinque indici di utilizzo di Internet (*idxsal*, *idxsoc*, *idxfin*, *idxint*, *idxinf*), con lo scopo di distinguere profili di utenti caratterizzati da modalità di fruizione diverse.

5.1.1 Indice di silhouette

Un aspetto fondamentale nella cluster analysis è la scelta del numero ottimale di gruppi k . Per valutare la bontà della partizione si utilizza l'indice di *silhouette*.

Per ogni unità i si definisce:

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}},$$

dove:

- $a(i)$ = distanza media dell'unità i dalle altre unità del suo cluster,
- $b(i)$ = minima distanza media dell'unità i da tutte le unità appartenenti a un altro cluster (cioè il cluster con distanza minore da i).

Il valore di $s(i)$ varia tra -1 e 1 :

- valori prossimi a 1 indicano un'ottima assegnazione,
- valori vicini a 0 indicano punti al confine tra due cluster,
- valori negativi suggeriscono un'assegnazione potenzialmente errata.

La **silhouette media** è la media di $s(i)$ su tutte le unità e fornisce una misura globale di coesione interna e separazione esterna dei cluster. Tale valore viene utilizzato per confrontare diverse soluzioni con differenti valori di k , il numero di cluster che massimizza la silhouette media è considerato quello più appropriato, pur tenendo conto anche dell'interpretabilità delle soluzioni.

Nel nostro caso, i valori della silhouette sono stati calcolati su un **sottocampione casuale semplice di 10 000 individui**¹, al fine di ridurre i tempi di calcolo. Successivamente, i risultati definitivi sono stati ottenuti applicando il metodo k-means all'intero campione.

5.2 Cluster analysis sugli indici

Sui cinque indici $idxsal$, $idxsoc$, $idxfin$, $idxint$, $idxinf$ è stato applicato il *k-means*. La scelta di k è stata guidata dalla **silhouette media** calcolata per $k = 2, \dots, 5$ sul sottocampione.

¹Il campione è casuale semplice, quindi ogni unità ha uguale probabilità di inclusione; si riduce il costo computazionale senza introdurre distorsioni sistematiche nelle distribuzioni.




Figura 5.1: Curva silhouette media per $k = 2, \dots, 5$ (sottocampione di 10 000 unità). Il valore massimo si osserva a $k = 2$, ma le differenze con $k = 3$, $k = 4$ o $k = 5$ sono contenute, suggerendo una struttura più articolata.

La Figura 5.1 mostra un massimo a $k = 2$; tuttavia, la perdita di silhouette passando a $k = 3$ o $k = 4$ è modesta, il che giustifica l'esplorazione di soluzioni più ricche in termini interpretativi. Abbiamo quindi stimato la soluzione con $k = 4$, che separa profili d'uso sostanzialmente diversi.

5.2.1 Risultati statistici della soluzione a $k = 4$

Il rapporto tra la somma dei quadrati tra cluster e la somma totale dei quadrati è pari al **52,3%**. Questo valore riflette la quota di variabilità totale spiegata dal clustering, ossia quanto la suddivisione in quattro gruppi riesca a distinguere i dati in modo significativo tra cluster anziché all'interno dei cluster stessi. Un valore del genere è considerabile discreto ma non ottimo, indicando una separazione sufficiente tra i gruppi individuati. Le **dimensioni dei cluster** sono le seguenti:

- Cluster 1: 9505 individui
- Cluster 2: 9299 individui
- Cluster 3: 12091 individui
- Cluster 4: 9309 individui

Tutti i cluster risultano ben numerosi e bilanciati, evitando la presenza di gruppi troppo piccoli che potrebbero rappresentare outlier o distorsioni campionarie. Questo equilibrio numerico garantisce maggiore stabilità e credibilità alla segmentazione ottenuta.

Le **medie** dei cinque indici nei quattro cluster sono:

Cluster	idxsal	idxsoc	idxfin	idxint	idxinf
1	0.1725	0.2093	0.0894	0.2039	0.1875
2	0.4558	0.0252	0.2256	0.3768	0.8271
3	0.1937	0.7234	0.1883	0.5683	0.7558
4	0.8120	0.7617	0.3364	0.6925	0.8723

Tabella 5.1: Centroidi (medie degli indici) per la soluzione $k = 4$.

5.2.2 Interpretazione dei cluster

L'analisi dei centroidi dei quattro cluster mette in luce profili di utilizzo di Internet tra loro ben distinti. In particolare, emergono le seguenti tipologie:

- C1 (*utilizzatori marginali*)** Questo gruppo si caratterizza per valori bassi in tutti gli indici. L'uso di Internet è limitato e poco diversificato: attività come informazione, utilizzo social, intrattenimento e servizi risultano tutte scarsamente praticate. Si tratta quindi di individui che possiamo definire *marginalmente connessi*, spesso con minori competenze digitali, dove la presenza in rete è sporadica e legata a necessità specifiche piuttosto che a un impiego quotidiano.
- C2 (*info-only / anti-social*)** Questo cluster mostra valori elevati su *idxinf* (informazione) e, in misura più contenuta, su *idxsal* (servizi), mentre si distingue per un livello quasi nullo di *idxsoc* (socializzazione). Il profilo che emerge è quello di un utilizzatore che sfrutta il web prevalentemente come strumento informativo e, in parte, per servizi utilitaristici (ad es. servizi legati alla sanità), ma non lo impiega come ambiente relazionale. Questo pattern può riflettere individui interessati a sfruttare le potenzialità informative di Internet ma meno legati alle dinamiche di comunità online.
- C3 (*social & info*)** Gli appartenenti a questo cluster si caratterizzano per un uso intenso di Internet a scopo sociale (*idxsoc* alto) e informativo (*idxinf* alto), accompagnato da valori medi su intrattenimento e finanza. La loro identità digitale appare quindi centrata sulla dimensione *comunicativa e informativa*: sono utenti che utilizzano la rete per mantenere relazioni sociali, partecipare a comunità online, ma anche per aggiornarsi su notizie e contenuti.
- C4 (*heavy multipurpose*)** Questo cluster rappresenta gli utenti più avanzati e digitalmente integrati. Gli indici sono alti in tutte le dimensioni: socializzazione, informazione, intrattenimento, servizi e, in misura maggiore rispetto agli altri cluster, anche la finanza. Questi individui utilizzano Internet a 360 gradi, per scopi sia ludici che strumentali, dimostrando competenze trasversali e una piena appropriazione delle

opportunità offerte dal digitale. Il profilo corrisponde agli *heavy users* polivalenti, spesso giovani o adulti in età lavorativa con un'elevata istruzione nella quasi totalità dei casi, capaci di sfruttare Internet come risorsa quotidiana e multifunzionale.

In sintesi, la segmentazione a quattro cluster consente di distinguere non solo un gradiente di intensità, ma anche diverse combinazioni di utilizzo: dall'uso puramente informativo, a quello social, fino alla fruizione estesa e multidimensionale.

5.2.3 Profili sociali nella soluzione a quattro cluster




Figura 5.2: Rappresentazione grafica della soluzione a $k = 4$ (profili degli indici per cluster delle variabili categoriali ordinate).

Le Figure 5.2- 5.3 consentono di analizzare in modo più dettagliato i quattro cluster individuati. Il **Cluster 1 (utilizzatori marginali)** mostra una maggiore concentrazione nelle fasce di età più elevate e tra gli inattivi, con livelli di istruzione medio-bassi. Il **Cluster 2 (info-only / anti-social)**




Figura 5.3: Rappresentazione grafica della soluzione a $k = 4$ (profili degli indici per cluster, variabili categoriali non ordinate).

presenta una struttura anagrafica mista ma con un'incidenza significativa di adulti e anziani, spesso occupati, che utilizzano la rete principalmente per informazione e servizi. Nel **Cluster 3 (social & info)** si osserva una presenza più marcata di individui giovani e adulti con titolo di studio più elevato, tipici di un profilo che combina relazioni sociali online e ricerca informativa; la distribuzione per sesso risulta bilanciata, a conferma di una diffusione trasversale di queste pratiche. Infine, il **Cluster 4 (heavy multipurpose)** comprende utenti con istruzione mediamente più alta, occupati e residenti soprattutto nelle aree del Nord, che utilizzano Internet in tutte le sue dimensioni, si tratta degli *heavy users*. Un aspetto rilevante che emerge dal confronto tra i cluster riguarda le variabili *cittadinanza* e *sesso*. A differenza di età, condizione occupazionale, titolo di studio e area geografica, queste due caratteristiche non mostrano sostanziali sbilanciamenti tra i gruppi individuati: la distribuzione tra italiani e stranieri, così come quella tra maschi e femmine, appare infatti relativamente omogenea. Ciò suggerisce che tali fattori non svolgono un ruolo discriminante nelle modalità d'uso di Internet, e che le differenze più marcate sono inve-

ce riconducibili ad altre dimensioni socio-demografiche. Questo risultato conferma che il digital divide non è uniformemente distribuito, ma si concentra su specifici assi di disuguaglianza, mentre in altri ambiti l'utilizzo delle tecnologie appare diffuso in maniera trasversale.

5.3 Conclusioni

L'analisi condotta ha permesso di individuare e descrivere con chiarezza i profili di utilizzo di Internet presenti nella popolazione. Dal punto di vista metodologico, l'impiego della silhouette ha fornito una prima indicazione sul numero ottimale di cluster, suggerendo una soluzione a $k = 2$. Tuttavia, la scelta di approfondire la segmentazione con $k = 4$ si è rivelata particolarmente fruttuosa: pur comportando una leggera perdita in termini di silhouette media, ha consentito di distinguere gruppi molto più informativi e interpretabili.

I quattro cluster emersi descrivono in maniera articolata il digital divide: dagli *utilizzatori marginali*, poco presenti online e concentrati tra fasce anagrafiche più elevate, agli *info-only*, che usano la rete quasi esclusivamente come fonte informativa, passando per gli utenti *social & info*, che integrano comunicazione e accesso ai contenuti, fino agli *heavy multipurpose*, digitalmente avanzati e capaci di sfruttare Internet in tutte le sue dimensioni.

Capitolo 6

Interazioni e importanza delle variabili nei modelli Random Forest

Obiettivo. Valutare come i predittori socio-demografici ($ETAM_i$, $ISTR-M_i$, $SESSO$, GEO , $CONDM_i$, $CITTM_i$) contribuiscono agli indici $idxFUN$, $idxSERIO$ e $idxTOT$. Distinguiamo tra: (i) **importanza marginale** dei singoli predittori (*permutation importance*) e (ii) **interazioni** tra predittori (*non-additività*).

6.1 Cenni sul Random Forest e sulle metriche usate

Idea di base. Un *Random Forest* (RF) è un **insieme** di alberi CART (Classification and Regression Trees) costruiti su versioni *bootstrap* del campione, con ulteriore casualizzazione nella scelta dei predittori a ogni split. La previsione finale è l'aggregazione delle previsioni dei singoli alberi.

Bootstrap (bagging) Per ciascun albero b si costruisce un *campione bootstrap* di dimensione n selezionando n unità dal dataset originale **con reinserimento** (ogni unità può essere scelta più volte). Ne consegue che alcune osservazioni compaiono più di una volta, mentre altre non compaio-

no affatto. Le osservazioni non selezionate per l'albero b sono dette **Out-Of-Bag (OOB)** e vengono utilizzate per stimare internamente l'errore predittivo dell'albero (e dell'RF) senza ricorrere a un set di test separato. *Esempio:* con unità $\{1, 2, 3, 4, 5\}$ un campione possibile è $\{1, 3, 3, 4, 5\}$; l'unità 2 è OOB, mentre l'unità 3 è presente 2 volte.

Il vantaggio del Bagging unito al sorteggio casuale delle variabili è la **Decorrelazione dei modelli**. Usare campioni diversi (bootstrap) fa sì che gli alberi non siano tutti simili a causa della presenza di una variabile dominante. Quando gli errori dei singoli modelli non sono perfettamente allineati, la media li compensa.

Costruzione di ciascun albero.

1. ad ogni nodo si sorteggiano m predittori tra i p disponibili (per ridurre la correlazioni tra alberi);
2. si sceglie lo *split* migliore tra quelli disponibili (criterio di impurità): MSE per la regressione; Gini/entropia per la classificazione;
3. si prosegue ricorsivamente fino a nodi piccoli (**nodesize**) o limite di nodi (**maxnodes**).

Importanza marginale. La *permutation importance* misura l'aumento dell'errore *out of bag* (OOB) quando si permuta una variabile tenendo fisso tutto il resto, maggiore è l'aumento, maggiore sarà il contributo informativo della variabile.

Interazioni (*minimal depth*). Con `randomForestExplainer` stimiamo la *mean minimal depth* delle coppie $X_j : X_k$, prima un'interazione compare negli alberi, più è rilevante. Usiamo anche le *occorrenze* della coppia come criterio secondario.

Controllo visivo: PDP 2D. I *Partial Dependence Plot* (PDP) su due predittori mostrano l'effetto medio congiunto sulla risposta. Le mappe sono rese come *heatmap* per tutte le combinazioni di classi.

6.2 Setup dei modelli

Per ciascun indice ($idxFUN$, $idxSERIO$, $idxTOT$) stimiamo una RF con $n_{tree} = 500$ e le stesse covariate: $ETAMi$, $ISTRMi$, $SESSO$, GEO , $CONDMi$, $CITTMi$. Le variabili categoriali sono ricodificate come fattori; $ETAMi$ e $ISTRMi$ sono fattori *ordinati*. Inoltre è importante tenere conto che $CITTMi$ è sbilanciata (quota di stranieri molto ridotta), perciò i dati relativi vanno letti con cautela.

6.3 Importanza marginale




Figura 6.1: Importanza delle variabili – $idxFUN$

Lettura. $ETAMi$ e $ISTRMi$ sono sistematicamente rilevanti. Per $idxFUN$ primeggia $ETAMi$ (segue $ISTRMi$); per $idxSERIO$ spiccano $ISTRMi$, GEO e $ETAMi$; per $idxTOT$ contano $ETAMi$, $ISTRMi$ e $CONDMi$. $CITTMi$ e $SESSO$ risultano marginali.

IncNodePurity. Nei Random Forest questa misura (detta anche *Mean Decrease in Impurity*) quantifica, per ciascuna variabile, il guadagno medio di “purezza” prodotto dagli split che la utilizzano. Ad ogni split si calcola

$$\Delta I = I(t) - p_S I(t_S) - p_D I(t_D),$$

Importanza variabili - idxSERIO




Figura 6.2: Importanza delle variabili – *idxSERIO*

Importanza variabili - idxTOT




Figura 6.3: Importanza delle variabili – *idxTOT*

dove $I(\cdot)$ è l'impurità del nodo (I = somma dei residui/varianza nelle regressioni; indice di Gini o entropia nelle classificazioni) e p_D, p_S sono le proporzioni di campioni nei nodi figli (D per destra ed S per sinistra). La somma di ΔI su tutti gli alberi fornisce l'*increase in node purity* per variabile: valori maggiori indicano predittori più utili.

6.4 Selezione delle coppie per i PDP 2D

Criteri operativi per scegliere le coppie dei PDP 2D

Minimal depth (idea). In un albero RF la *minimal depth* di X_j è la profondità del primo nodo in cui X_j compare. Per l'interazione $X_j : X_k$ consideriamo, per ogni albero, la profondità minima a cui X_k compare nel sottoalbero radicato in X_j ; aggregando otteniamo la media $\bar{d}_{k|j}$ e le occorrenze $\text{occ}_{k|j}$. Confrontiamo $\bar{d}_{k|j}$ con la *minimal depth non condizionata* $\bar{d}_k^{\text{uncond}}$: se $\bar{d}_{k|j} < \bar{d}_k^{\text{uncond}}$, l'interazione è rilevante.

Procedura.

1. **Calcolo:** `min_depth_interactions()` $\Rightarrow \bar{d}_{k|j}, \text{occ}_{k|j}, \bar{d}_k^{\text{uncond}}$.
2. **Pulizia:** rimuoviamo auto-coppie ($j = k$).
3. **Ranking:** ordiniamo per $\bar{d}_{k|j}$ crescente; a parità, per $\text{occ}_{k|j}$ decrescente.
4. **Scelta & PDP:** selezioniamo le coppie forti e interpretabili per il digital divide (es. $ETAMi \times ISTRMi$, $ETAMi \times CONDMi$, $ETAMi \times GEO$) e ne tracciamo i PDP 2D (heatmap) per verificare non-additività.

Esempi (sintesi). $idxSERIO: ETAMi \rightarrow CONDMi \bar{d} = 0.827 < 1.650$ (occ 491) $\Rightarrow$ forte; $idxTOT: ETAMi \rightarrow ISTRMi \bar{d} = 0.709 < 1.082$ (occ 494) $\Rightarrow$ selezionata.

6.5 Lettura dei grafici di *minimal depth* e scelta delle coppie

I tre grafici 6.4, 6.5 e 6.6 mostrano, per ciascun indice, la **profondità minima media** delle interazioni a coppie: barre più basse indicano interazioni più forti; la **linea rossa** è una soglia di riferimento; il pallino nero riporta la profondità media *non condizionata* (utile per vedere se, una volta condizionato su X_j , X_k entra più in alto nell'albero).




Figura 6.4: Interazioni (minimal depth) – *idxFUN*. Barre più basse = interazione più forte.




Figura 6.5: Interazioni (minimal depth) – *idxSERIO*.




Figura 6.6: Interazioni (minimal depth) – *idxTOT*.

idxFUN (Fig. 6.4)

- Le interazioni risultano complessivamente deboli: nessuna coppia scende sotto la soglia; la più bassa è **ETAMi**→**CONDMi**, ma resta marginale. Nel complesso la struttura è quasi additiva.

Implicazione. Per *idxFUN* la struttura sembra semplicemente additiva; le interazioni utili ai fini interpretativi sono poche e tutte legate all'età.

idxSERIO (Fig. 6.5)

- Spiccano tre coppie con profondità condizionata bassa e molte occorrenze: **ETAMi**→**CONDMi**, **ETAMi**→**GEO** e **ETAMi**→**ISTRMi**. In tutti e tre i casi il pallino nero è sopra la barra (condizionata < non condizionata), segnale di interazione effettiva.
- le combinazioni che coinvolgono *SESSO* e *CITTMi* hanno profondità più alte e sono quindi secondarie.

Implicazione. Per *idxSERIO* l'età è il driver che attiva le interazioni principali: con la condizione occupazionale, con il territorio e con l'istruzione.

idxTOT (Fig. 6.6)

- La coppia **ETAMi**→**ISTRMi** è la più forte (barra più vicina/sotto la soglia) e con molte occorrenze.
- Seguono interazioni **territoriali** di media intensità (es. **GEO**→**CITTMi**, **GEO**→**SESSO**). Le coppie **ETAMi**→**GEO** e **ETAMi**→**CONDMi** risultano meno incisive rispetto a *idxSERIO*.

Implicazione. Su *idxTOT* l'unica interazione interessante sembra essere età-istruzione; la variabile territoriale invece presenta interazioni più deboli.

Conseguenze per i PDP 2D. Alla luce di queste evidenze, i PDP 2D sono focalizzati su:

- **ETAMi**×**ISTRMi** in *idxTOT* e *idxSERIO*;
- **ETAMi**×**CONDMi** e **ETAMi**×**GEO** per *idxSERIO* (forza elevata);

6.6 PDP 2D: evidenze visive delle non-additività

idxSERIO

Lettura. *idxSERIO* è fortemente modulato da *ETAMi*: l'effetto dell'istruzione cresce con l'età fino a metà ciclo di vita, poi rallenta; la condizione occupazionale separa in modo netto (occupati > disoccupati/inattivi). Il contesto territoriale incide: a parità di età, il Centro e il Nord mostrano livelli più elevati del Sud/Isole.

idxTOT

Lettura. L'indice complessivo eredita i pattern dei due componenti: forte gradiente per istruzione alle età centrali.




Figura 6.7: PDP 2D – $idxSERIO: ETAM_i \times ISTRM_i$.




Figura 6.8: PDP 2D – $idxSERIO: ETAM_i \times CONDM_i$.




Figura 6.9: PDP 2D – $idxSERIO: ETAMi \times GEO$.




Figura 6.10: PDP 2D – $idxTOT: ETAMi \times ISTRMi$.

6.7 Sintesi interpretativa

- **Ruolo dell'età.** $ETAMi$ è la leva principale e interagisce con istruzione, condizione occupazionale e territorio.

- **Istruzione.** L'aumento dell'istruzione ha un effetto positivo sull'utilizzo delle tecnologie digitali, questo effetto è più marcato su *idxSERIO*.
- **Condizione.** Gli occupati mostrano livelli più alti per quanto riguarda *idxSERIO*, mentre gli inattivi risultano più indietro nelle classi anziane.
- **Territorio.** Divario Nord/Centro vs Sud/Isole evidente su *idxSERIO*.
- **Variabili deboli.** *SESSO* e *CITTMi* hanno importanza modesta; per *CITTMi* pesa lo sbilanciamento campionario.

Nota metodologica. I PDP rappresentano effetti *medi* e possono attenuare/non riflettere eterogeneità nelle sottopopolazioni; infatti, nella fascia 14–15 anni, non sono presenti rispondenti con titolo di studio pari a diploma o laurea. Si tratta appunto di stime

Capitolo 7

Regressioni logistiche su

`idxFUN` e `idxSERIO`

7.1 Impostazione

Abbiamo stimato modelli logit con famiglia `quasibinomial` su due esiti binari, `idxFUN` e `idxSERIO`. L'età è stata centrata ($ETAc = ETA - \bar{ETA}$) e modellata in forma lineare e quadratica ($ETAc^2$), così da catturare curvature mantenendo interpretabilità (intercetta all'età media). Le variabili `SESSO`, `GEO`, `CITTMi` e `ISTRMi_u` sono fattori, `CONDMi` è un fattore ordinato. Per `CONDMi` riportiamo anche i contrasti polinomiali lineare (`.L`) e quadratico (`.Q`).¹

7.1.1 Fractional logit: modello, outcome e odds ratio

Il *fractional logit* è un modello a link logit per variabili risposta y comprese in $[0, 1]$, inclusi i casi limite 0 e 1. La media condizionata risulta essere:

$$\mu(x) \equiv E[y \mid x] = \Lambda(x^\top \beta) = \frac{1}{1 + \exp(-x^\top \beta)},$$

e si stima per massima quasi-verosimiglianza (*QMLE*) assumendo una varianza tipo Bernoulli $\text{Var}(y \mid x) = \mu(1 - \mu)$; la consistenza delle stime richiede la corretta specificazione della media. **L'outcome del modello**

¹Nel testo: `.L` indica il gradiente lineare sui livelli ordinati, `.Q` la componente non lineare.

sono quindi le *probabilità attese* $\hat{\mu}(x) \in [0, 1]$ per ciascun profilo di covariate: il modello produce direttamente previsioni di media interpretabili come proporzioni attese.

Un coefficiente β_j agisce sulla *scala del logit*:

$$\log\left(\frac{\mu}{1-\mu}\right) = x^\top \beta.$$

Per una variazione unitaria di x_j (a parità delle altre variabili) la differenza nel logit è $\Delta = \beta_j$; L'esponenziale del coefficiente fornisce l'**odds ratio**

$$\text{OR}_j = \exp(\beta_j),$$

cioè il fattore moltiplicativo con cui cambiano le *odds* della media μ (le odds sono $\mu/(1-\mu)$). Attenzione: l'OR descrive un effetto *sulla scala delle odds*, mentre l'effetto in termini di variazione di μ non è costante; infatti l'*effetto marginale* sulla scala di μ è

$$\frac{\partial \mu}{\partial x_j} = \mu(1-\mu) \beta_j,$$

massimo intorno a $\mu = 0,5$ e più piccolo vicino a 0 o a 1. Se y è propriamente binaria, la fractional logit coincide con la logistica standard; se y è frazionaria (es. tassi di utilizzo), il modello garantisce previsioni sempre nell'intervallo $[0, 1]$.

7.2 Variabili considerate

Variabili comuni:

- **Età:** centrata ($\text{ETAc} = \text{ETA} - \bar{\text{ETA}}$) e termine quadratico ETAc^2 (solo nei modelli quadratici); nel modello base si usa ETA non centrata.
- **Istruzione:** ISTRMi_u (fattore con livelli espliciti: Laurea [rif.]², Diploma, Media, Elementare). Nel solo modello base si usa ISTRMi

²Con [rif.] indichiamo la modalità di riferimento (categoria base) della variabile: il relativo effetto è assorbito nell'intercetta.

con contrasti polinomiali (.L, .Q, .C).

- **Area geografica** (GEO): Nord [rif.], Centro, Sud/Isole.
- **Condizione** (CONDMi): fattore ordinato, contrasto lineare (.L) e quadratico (.Q).
- **Sesso** (SESSO): Maschio [rif.], Femmina.
- **Cittadinanza** (CITTMi): Italiana [rif.], Straniera.
- **Modello base** (mfun0, mserio0): *effetti principali* soltanto.
Variabili incluse: ETA (non centrata), ISTRMi (.L, .Q, .C), GEO, CONDMi (.L, .Q), SESSO, CITTMi.
Interazioni: nessuna.
- **Modello quadratico con interazioni mirate** (mfunq, mserioq):
Effetti principali (comuni): ETAc, ETAc², ISTRMi_u, GEO, CONDMi (.L, .Q), SESSO, CITTMi.
Interazioni per idxFUN (mfunq):
 - (ETAc+ETAc²) × {SESSO, GEO, ISTRMi_u, CONDMi, CITTMi}
(5 blocchi età × fattore)
 - GEO × {ISTRMi_u, CONDMi, SESSO}
 - SESSO × {ISTRMi_u, CONDMi}*Interazioni per idxSERIO (mserioq)*:
 - (ETAc + ETAc²) × {CONDMi, GEO, ISTRMi_u}
 - GEO × {ISTRMi_u, CONDMi, CITTMi}
 - CONDMi × ISTRMi_u, SESSO × ISTRMi_u
- **Versione potata** (mfunr, mserior): *stesse variabili principali* del modello quadratico; si mantengono solo le interazioni risultate significative nella stima completa.
Interazioni mantenute per idxFUN (mfunr):

ETAc:CONDMi, ETAc²:SESSO, ETAc²:ISTRMi_u,
ETAc²:CONDMi, ISTRMi_u:SESSO, CONDMi:SESSO.

Interazioni mantenute per *idxSERIO* (*mserior*):

ETAc:CONDMi, ETAc:ISTRMi_u, ETAc²:CONDMi,
ETAc²:ISTRMi_u, GEO:CONDMi, ISTRMi_u:CONDMi, ISTRMi_u:SES

- **Quasi-saturo** (*mfunsat*, *mseriosat*):

Effetti principali: ETAc, ETAc², ISTRMi_u, GEO, CONDMi (.L, .Q), SESSO, CITTMi.

Interazioni fra fattori (tutte le 2-vie):

$$(ISTRMi_u + GEO + CONDMi + SESSO + CITTMi)^2.$$

Interazioni età × fattore:

$$(ETAc + ETAc^2) \times (ISTRMi_u + GEO + CONDMi + SESSO + CITTMi).$$

7.3 Bontà di adattamento

Verifichiamo la quota di devianza spiegata rispetto alla devianza totale:

$$R_D^2 = 1 - \text{Dev}_{\text{res}} / \text{Dev}_{\text{null}}.$$

Tabella 7.1: Sintesi di devianza e dispersione

Modello	Dev _{null}	Dev _{res}	R_D^2 (%)
idxFUN: m0	17095.0	13467.0	21.2
idxFUN: m_fun_q	17095.0	13410.0	21.6
idxFUN: m_fun_q_sig	17095.0	13415.0	21.5
idxFUN: m_fun_qsat_A	17095.0	13403.0	21.6
idxSERIO: m0	9426.8	7942.6	15.7
idxSERIO: m_serio_q	9426.8	7865.5	16.6
idxSERIO: m_serio_q_sig	9426.8	7868.3	16.5
idxSERIO: m_serio_qsat_A	9426.8	7807.7	17.2

In entrambi gli esiti, la specifica con ETAc e ETAc² migliora il fit; il modello quasi-saturo aggiunge un guadagno piccolo ma consistente.

7.4 Risultati per idxFUN

Tutti i risultati sono riportati nelle Tab. 7.2–7.9.

Effetti principali

- **Età.** La pendenza è nettamente negativa ($ETAc < 0$, $p < 10^{-16}$) con curvatura concava ($ETAc^2 < 0$, $p < 0.001$): all'aumentare dell'età le *odds* diminuiscono e lo fanno in modo non lineare. Attorno all'età media, un incremento di 10 anni implica $\Delta\text{logit} \approx 10\beta_1 + 100\beta_2 \simeq -0.37$, per cui $OR_{10} \approx e^{-0.37} \simeq 0.69$. In altre parole, a parità di tutto il resto le *odds* sono circa il 31% più basse dieci anni sopra l'età media (la variazione dipende dal livello di partenza).
- **Istruzione.** Rispetto a *Laurea* (riferimento) i coefficienti sono negativi e altamente significativi: *Diploma* $OR \approx e^{-0.340} \simeq 0.71$, *Media* $OR \approx e^{-0.667} \simeq 0.51$, *Elementare* $OR \approx e^{-0.852} \simeq 0.43$. Dunque livelli di istruzione più bassi sono associati a probabilità inferiori di esito favorevole.
- **Geografia.** *Centro* ha effetto positivo ($OR \approx e^{0.079} \simeq 1.08$), *Sud/Isole* negativo ($OR \approx e^{-0.086} \simeq 0.92$) rispetto al Nord: permangono differenze territoriali nette.
- **Genere e cittadinanza.** *Femmina* ($OR \approx 0.80$) e *Straniera* ($OR \approx 0.81$) presentano odds inferiori rispetto ai rispettivi riferimenti.
- **CONDMi.** Il contrasto quadratico .Q è positivo e significativo ($OR \approx e^{0.120} \simeq 1.13$), indicando una componente non lineare tra i livelli ordinati; il contrasto lineare .L risulta talvolta non significativo.

Interazioni rilevanti

- $ETAc \times CONDMi.L < 0$ (***)³. La *pendenza* dell'età si fa più negativa muovendosi lungo il gradiente lineare di CONDMi. In termini

³Significato degli asterischi: *** $p < 0,001$, ** $p < 0,01$, * $p < 0,05$, $\cdot p < 0,10$. Test di Wald su scala logit

di +10 anni, il contributo aggiuntivo è circa $10 \times (-0.0033) \approx -0.033$ sulla scala del logit per un'unità di .L.

- **ETAc² × CONDMi.L** > 0 (***) . La *curvatura* si attenua ai livelli alti di CONDMi: su +10 anni l'aggiunta è $\approx 100 \times 0.000233 \simeq 0.023$ di logit per unità di .L.
- **ETAc² × SESSO** > 0 (*). Nelle donne la curva età–logit è leggermente meno concava (su +10 anni l'aggiunta è ≈ 0.012 di logit), quindi il calo con l'età è un po' meno marcato.
- **ETAc² × ISTRMi_u** (*Diploma* **, *Media* ***). La curvatura varia per titolo: su +10 anni l'incremento di logit è ≈ 0.018 (Diploma) e ≈ 0.027 (Media), attenuando parzialmente il calo medio.
- **CONDMi × SESSO** (.L **, .Q ***). Il differenziale di genere dipende dai livelli di CONDMi (sia nella componente lineare sia in quella non lineare).
- **GEO × CITTMi** (nel quasi-saturo). È significativo il contrasto *Sud/Isole:Straniera*, segnalando che il divario per cittadinanza non è omogeneo sul territorio.

7.5 Risultati per idxSERIO

Effetti principali

- **Età.** La curvatura è chiaramente concava ($\text{ETAc}^2 < 0$, $p < 10^{-14}$). Attorno all'età media, +10 anni comportano $\Delta\text{logit} \simeq -0.084$ e quindi $\text{OR}_{10} \approx e^{-0.084} \approx 0.92$ (riduzione di odds $\sim 8\%$).
- **Istruzione.** Forti gradienti: *Diploma* OR ≈ 0.74 , *Media* OR ≈ 0.46 , *Elementare* OR ≈ 0.31 vs *Laurea* (tutti ***).
- **Geografia.** *Sud/Isole* negativo (OR ≈ 0.66 , ***); *Centro* negativo più lieve (OR ≈ 0.89 , ***).
- **CONDMi.** .L negativo (***) e .Q positivo (**): profilo non monotono lungo i livelli ordinati.

- **Genere e cittadinanza.** *Femmina* OR ≈ 0.92 (***) e *Straniera* OR ≈ 0.83 (**).

Interazioni rilevanti

- **ETAc $\times$ CONDMi.L > 0 (***)**. La pendenza con l'età è meno negativa ai livelli alti di CONDMi.
- **ETAc² $\times$ CONDMi.L > 0 (***)**. La concavità si attenua lungo CONDMi.
- **ETAc $\times$ ISTRMi_u (*Media* *)**. A istruzione intermedia la pendenza con l'età è più favorevole.
- **ETAc² $\times$ ISTRMi_uElementare > 0 (*)**. Curvatura differente al livello più basso di istruzione.
- **GEO $\times$ CONDMi.Q**. Effetto positivo per *Sud/Isole* (significativo/limite), indice di eterogeneità territoriale nella componente non lineare di CONDMi.
- **ISTRMi_u $\times$ CONDMi**. Più contrasti significativi: l'associazione di CONDMi varia per titolo.
- **ISTRMi_u $\times$ SESSO (*Media* **)**. Il divario di genere risulta più pronunciato a istruzione intermedia.
- **(Quasi-saturo)**. Compagnono pendenze età più sfavorevoli per *Femmina* e *Straniera* (ETAc $\times$ SESSO/ CITTMi negative e molto significative), evidenziando eterogeneità residua.

7.6 Lettura trasversale e implicazioni

- La modellazione **quadratica dell'età** cattura bene la non-linearità, la pendenza locale è $\beta_{\text{ETAc}} + 2\beta_{\text{ETAc}^2} \text{ETAc}$.
- Le **differenze per titolo, territorio, genere e cittadinanza** sono robuste e consistenti su entrambi gli indici.

- Le **interazioni con CONDMi** sono sistematiche (lineari e quadratiche).
- I guadagni del quasi-saturo sono *moderati* in termini di devianza spiegata; tuttavia, rivelano interazioni significative utili per la discussione.

Tabella 7.2: Coefficients — modello base per `idxFUN` (`m0fun`).

Termine	Estimate	Std. Error	t value	Sig.
(Intercept)	1.5199	0.0238	63.9060	***
ETA	−0.0353	0.0004	−95.2020	***
ISTRMi.L	−0.5539	0.0266	−20.8070	***
ISTRMi.Q	0.0329	0.0207	1.5920	
ISTRMi.C	0.0057	0.0128	0.4430	
GEOCentro	0.0796	0.0149	5.3360	***
GEOSud/Isole	−0.0905	0.0131	−6.9250	***
CONDMi.L	0.0081	0.0093	0.8710	
CONDMi.Q	0.0778	0.0161	4.8410	***
SESSOFemmina	−0.1593	0.0115	−13.8420	***
CITTMiStraniera	−0.2268	0.0349	−6.5080	***

Tabella 7.3: Coefficients — modello base per `idxSERIO` (`m0serio`).

Termine	Estimate	Std. Error	t value	Sig.
(Intercept)	−0.5474	0.0184	−29.7190	***
ETA	0.0000	0.0003	−0.0530	
ISTRMi.L	−0.8851	0.0211	−41.8620	***
ISTRMi.Q	−0.0323	0.0164	−1.9700	*
ISTRMi.C	0.0495	0.0102	4.8460	***
GEOCentro	−0.0998	0.0115	−8.6790	***
GEOSud/Isole	−0.3919	0.0103	−38.0670	***
CONDMi.L	−0.1839	0.0072	−25.5580	***
CONDMi.Q	0.0901	0.0129	6.9740	***
SESSOFemmina	−0.0290	0.0089	−3.2440	**
CITTMiStraniera	−0.1675	0.0279	−6.0060	***

Tabella 7.8: Coefficients — `idxFUN` quasi-saturo (`mfunsat`, quasibinomial logit).

Termine	Estimate	Std. Error	t value	Sig.
(Intercept)	0.2471	0.0376	6.5760	***
ETAc	−0.0345	0.0013	−27.2600	***
I(ETAc ²)	−0.0002	0.0001	−2.6750	**

Continua a pagina seguente

Termine	Estimate	Std. Error	t value	Sig.
ISTRMi.uDiploma	-0.2989	0.0371	-8.0550***	
ISTRMi.uMedia	-0.6006	0.0420	-14.2900***	
ISTRMi.uElementare	-0.9101	0.1019	-8.9310***	
GEOCentro	0.0215	0.0435	0.4950	
GEOSud/Isole	-0.1075	0.0381	-2.8240 **	
CONDMi.L	-0.0577	0.0376	-1.5340	
CONDMi.Q	0.1441	0.0511	2.8220 **	
SESSOFemmina	-0.2378	0.0334	-7.1120***	
CITTMiStraniera	-0.2448	0.1044	-2.3460 *	
ISTRMi.uDiploma:GEOCentro	0.0129	0.0362	0.3560	
ISTRMi.uMedia:GEOCentro	-0.0211	0.0440	-0.4790	
ISTRMi.uElementare:GEOCentro	0.0683	0.1090	0.6260	
ISTRMi.uDiploma:GEOSud/Isole	-0.0063	0.0325	-0.1930	
ISTRMi.uMedia:GEOSud/Isole	-0.0133	0.0388	-0.3430	
ISTRMi.uElementare:GEOSud/Isole	0.1535	0.0906	1.6940 .	
ISTRMi.uDiploma:CONDMi.L	0.0485	0.0309	1.5730 .	
ISTRMi.uMedia:CONDMi.L	0.0310	0.0360	0.8630	
ISTRMi.uElementare:CONDMi.L	0.0488	0.0876	0.5570	
ISTRMi.uDiploma:CONDMi.Q	-0.0225	0.0428	-0.5250	
ISTRMi.uMedia:CONDMi.Q	-0.1187	0.0497	-2.3900 *	
ISTRMi.uElementare:CONDMi.Q	-0.0127	0.1291	-0.0980	
ISTRMi.uDiploma:SESSOFemmina	0.0475	0.0284	1.6750 .	
ISTRMi.uMedia:SESSOFemmina	0.1199	0.0350	3.4260***	
ISTRMi.uElementare:SESSOFemmina	0.1329	0.0834	1.5940	
ISTRMi.uDiploma:CITTMiStraniera	-0.0700	0.0902	-0.7770	
ISTRMi.uMedia:CITTMiStraniera	-0.1313	0.1013	-1.2960	
ISTRMi.uElementare:CITTMiStraniera	0.0128	0.1898	0.0680	
GEOCentro:CONDMi.L	-0.0249	0.0317	-0.7840	
GEOSud/Isole:CONDMi.L	0.0337	0.0269	1.2540	
GEOCentro:CONDMi.Q	0.0629	0.0465	1.3530	
GEOSud/Isole:CONDMi.Q	0.0271	0.0374	0.7240	
GEOCentro:SESSOFemmina	0.0216	0.0306	0.7060	
GEOSud/Isole:SESSOFemmina	0.0404	0.0274	1.4730	
GEOCentro:CITTMiStraniera	0.0305	0.0824	0.3700	
GEOSud/Isole:CITTMiStraniera	0.3599	0.1223	2.9420 **	
CONDMi.L:SESSOFemmina	-0.0668	0.0255	-2.6220 **	
CONDMi.Q:SESSOFemmina	-0.1217	0.0340	-3.5740***	
CONDMi.L:CITTMiStraniera	-0.0302	0.0668	-0.4520	
CONDMi.Q:CITTMiStraniera	-0.0852	0.0790	-1.0770	
SESSOFemmina:CITTMiStraniera	0.0616	0.0766	0.8050	
ETAc:CONDMi.L	-0.0031	0.0007	-4.7230***	
I(ETAc ²) : <i>SESSOFemmina</i>	0.0001	0.0001	1.9720 *	
I(ETAc ²) : <i>ISTRMi.uMedia</i>	0.0002	0.0001	2.7880 **	
I(ETAc ²) : <i>CONDMi.L</i>	0.0002	0.0000	5.1800***	

Tabella 7.9: Coefficients — `idxSERIO` quasi-saturo (`mseriosat`, quasibino-
mial logit).

Termine	Estimate	Std. Error	t value	Sig.
(Intercept)	0.1342	0.0287	4.6780***	
ETAc	0.0002	0.0010	0.2280	
I(ETAc ²)	-0.0005	0.0001	-8.2170***	
ISTRMi.uDiploma	-0.2995	0.0284	-10.5630***	
ISTRMi.uMedia	-0.7628	0.0327	-23.3300***	

Continua a pagina seguente

Termine	Estimate	Std. Error	t value	Sig.
ISTRMi.uElementare	-1.2940	0.0839	-15.4270	***
GEOCentro	-0.0863	0.0332	-2.5970	**
GEOSud/Isole	-0.3862	0.0295	-13.1070	***
CONDMi.L	-0.0550	0.0284	-1.9390	.
CONDMi.Q	0.2274	0.0397	5.7320	***
SESSOFemmina	-0.0749	0.0257	-2.9180	**
CITTMiStraniera	-0.2446	0.0816	-2.9990	**
ISTRMi.uDiploma:GEOCentro	-0.0012	0.0274	-0.0460	
ISTRMi.uMedia:GEOCentro	-0.0395	0.0341	-1.1600	
ISTRMi.uElementare:GEOCentro	0.0581	0.0836	0.6950	
ISTRMi.uDiploma:GEOSud/Isole	-0.0192	0.0249	-0.7720	
ISTRMi.uMedia:GEOSud/Isole	-0.0599	0.0307	-1.9520	.
ISTRMi.uElementare:GEOSud/Isole	-0.0335	0.0739	-0.4540	
ISTRMi.uDiploma:CONDMi.L	0.0354	0.0233	1.5180	
ISTRMi.uMedia:CONDMi.L	0.0182	0.0278	0.6540	
ISTRMi.uElementare:CONDMi.L	-0.0663	0.0702	-0.9440	
ISTRMi.uDiploma:CONDMi.Q	-0.0815	0.0331	-2.4620	*
ISTRMi.uMedia:CONDMi.Q	-0.1169	0.0399	-2.9330	**
ISTRMi.uElementare:CONDMi.Q	0.0092	0.1153	0.0800	
ISTRMi.uDiploma:SESSOFemmina	0.0512	0.0216	2.3660	*
ISTRMi.uMedia:SESSOFemmina	0.1262	0.0272	4.6390	***
ISTRMi.uElementare:SESSOFemmina	0.1857	0.0650	2.8560	**
ISTRMi.uDiploma:CITTMiStraniera	-0.0330	0.0700	-0.4720	
ISTRMi.uMedia:CITTMiStraniera	0.0115	0.0800	0.1440	
ISTRMi.uElementare:CITTMiStraniera	0.2013	0.1583	1.2720	
GEOCentro:CONDMi.L	-0.0181	0.0242	-0.7460	
GEOSud/Isole:CONDMi.L	-0.0222	0.0209	-1.0630	
GEOCentro:CONDMi.Q	0.0373	0.0362	1.0300	
GEOSud/Isole:CONDMi.Q	0.0534	0.0298	1.7930	.
GEOCentro:SESSOFemmina	-0.0221	0.0234	-0.9450	
GEOSud/Isole:SESSOFemmina	-0.0417	0.0214	-1.9500	.
GEOCentro:CITTMiStraniera	0.0045	0.0655	0.0690	
GEOSud/Isole:CITTMiStraniera	0.1487	0.1016	1.4540	
CONDMi.L:SESSOFemmina	-0.1167	0.0194	-6.0100	***
CONDMi.Q:SESSOFemmina	-0.1652	0.0270	-6.1200	***
CONDMi.L:CITTMiStraniera	0.0345	0.0529	0.6520	
CONDMi.Q:CITTMiStraniera	-0.0802	0.0630	-1.2730	
SESSOFemmina:CITTMiStraniera	-0.0503	0.0604	-0.8320	
ETAc:ISTRMi.uDiploma	0.0006	0.0008	0.7660	
ETAc:ISTRMi.uMedia	0.0013	0.0009	1.3910	
ETAc:ISTRMi.uElementare	-0.0012	0.0040	-0.2880	
ETAc:GEOCentro	0.0009	0.0008	1.1870	
ETAc:GEOSud/Isole	-0.0009	0.0007	-1.2700	
ETAc:CONDMi.L	0.0021	0.0005	4.2420	***
ETAc:CONDMi.Q	-0.0005	0.0014	-0.3220	
ETAc:SESSOFemmina	-0.0069	0.0006	-11.3150	***
ETAc:CITTMiStraniera	-0.0112	0.0027	-4.1830	***
I(ETAc ²) : <i>ISTRMi.uDiploma</i>	0.0000	0.0001	0.6500	
I(ETAc ²) : <i>ISTRMi.uMedia</i>	0.0000	0.0001	0.4770	
I(ETAc ²) : <i>ISTRMi.uElementare</i>	0.0004	0.0001	2.7210	**
I(ETAc ²) : <i>GEOCentro</i>	0.0000	0.0001	-0.8460	
I(ETAc ²) : <i>GEOSud/Isole</i>	0.0000	0.0000	0.8970	
I(ETAc ²) : <i>CONDMi.L</i>	0.0001	0.0000	3.4680	***
I(ETAc ²) : <i>CONDMi.Q</i>	0.0001	0.0001	0.7660	
I(ETAc ²) : <i>SESSOFemmina</i>	0.0000	0.0000	1.0280	
I(ETAc ²) : <i>CITTMiStraniera</i>	0.0002	0.0002	1.2020	

Tabella 7.4: Coefficients — idxFUN con termini quadratici e interazioni (mfunq).

Termine	Estimate	Std. Error	t value	Sig.
(Intercept)	0.2925	0.0319	9.1640	***
ETAc	−0.0343	0.0012	−28.1520	***
I(ETAc ²)	−0.0003	0.0001	−3.5130	***
ISTRMi_uDiploma	−0.3452	0.0283	−12.1880	***
ISTRMi_uMedia	−0.6658	0.0330	−20.1960	***
ISTRMi_uElementare	−0.9430	0.0903	−10.4470	***
GEOCentro	0.0173	0.0433	0.3980	
GEOSud/Isole	−0.1137	0.0377	−3.0150	**
CONDMi.L	−0.0210	0.0273	−0.7670	
CONDMi.Q	0.0870	0.0373	2.3320	*
SESSOFemmina	−0.2444	0.0330	−7.4040	***
CITTMiStraniera	−0.2281	0.0453	−5.0390	***
ETAc:SESSOFemmina	−0.0005	0.0008	−0.6750	
ETAc:GEOCentro	0.0009	0.0010	0.8980	
ETAc:GEOSud/Isole	0.0004	0.0009	0.4170	
ETAc:ISTRMi_uDiploma	0.0000	0.0010	0.0330	
ETAc:ISTRMi_uMedia	−0.0008	0.0012	−0.7070	
ETAc:ISTRMi_uElementare	−0.0021	0.0041	−0.5140	
ETAc:CONDMi.L	−0.0031	0.0007	−4.7210	***
ETAc:CONDMi.Q	0.0002	0.0018	0.1140	
ETAc:CITTMiStraniera	0.0010	0.0034	0.2830	
I(ETAc ²):SESSOFemmina	0.0001	0.0001	2.0170	*
I(ETAc ²):GEOCentro	0.0001	0.0001	1.0260	
I(ETAc ²):GEOSud/Isole	0.0000	0.0001	−0.3290	
I(ETAc ²):ISTRMi_uDiploma	0.0002	0.0001	3.1000	**
I(ETAc ²):ISTRMi_uMedia	0.0003	0.0001	4.0590	***
I(ETAc ²):ISTRMi_uElementare	0.0003	0.0002	1.8310	.
I(ETAc ²):CONDMi.L	0.0002	0.0000	5.0990	***
I(ETAc ²):CONDMi.Q	−0.0001	0.0001	−0.5520	
I(ETAc ²):CITTMiStraniera	0.0001	0.0002	0.6810	
ISTRMi_uDiploma:GEOCentro	0.0158	0.0361	0.4360	
ISTRMi_uMedia:GEOCentro	−0.0145	0.0440	−0.3300	
ISTRMi_uElementare:GEOCentro	0.0759	0.1084	0.7010	
ISTRMi_uDiploma:GEOSud/Isole	0.0026	0.0321	0.0810	
ISTRMi_uMedia:GEOSud/Isole	0.0086	0.0383	0.2250	
ISTRMi_uElementare:GEOSud/Isole	0.1665	0.0889	1.8730	.
GEOCentro:CONDMi.L	−0.0267	0.0317	−0.8440	
GEOSud/Isole:CONDMi.L	0.0319	0.0267	1.1920	
GEOCentro:CONDMi.Q	0.0683	0.0464	1.4720	
GEOSud/Isole:CONDMi.Q	0.0314	0.0369	0.8510	
GEOCentro:SESSOFemmina	0.0216	0.0306	0.7070	
GEOSud/Isole:SESSOFemmina	0.0419	0.0273	1.5360	
ISTRMi_uDiploma:SESSOFemmina	0.0546	0.0280	1.9450	.
ISTRMi_uMedia:SESSOFemmina	0.1204	0.0339	3.5560	***
ISTRMi_uElementare:SESSOFemmina	0.1479	0.0794	1.8630	.
CONDMi.L:SESSOFemmina	−0.0709	0.0253	−2.8040	**
CONDMi.Q:SESSOFemmina	−0.1108	0.0335	−3.3030	***

Tabella 7.5: Coefficients — `idxSERIO` con termini quadratici e interazioni (`mserioq`).

Termine	Estimate	Std. Error	t value	Sig.
(Intercept)	0.1290	0.0256	5.0470	***
ETAc	−0.0041	0.0009	−4.5540	***
I(ETAc ²)	−0.0005	0.0001	−7.7210	***
ISTRMi_uDiploma	−0.2919	0.0281	−10.4050	***
ISTRMi_uMedia	−0.7420	0.0321	−23.1500	***
ISTRMi_uElementare	−1.1400	0.0776	−14.7030	***
GEOCentro	−0.1009	0.0294	−3.4300	***
GEOSud/Isole	−0.4201	0.0255	−16.4670	***
CONDMi.L	−0.1494	0.0242	−6.1830	***
CONDMi.Q	0.0997	0.0350	2.8470	**
SESSOFemmina	−0.0829	0.0172	−4.8140	***
CITTMiStraniera	−0.2031	0.0342	−5.9350	***
ETAc:CONDMi.L	0.0019	0.0005	3.7840	***
ETAc:CONDMi.Q	0.0006	0.0014	0.4390	
ETAc:GEOCentro	0.0011	0.0008	1.3690	
ETAc:GEOSud/Isole	−0.0002	0.0007	−0.3240	
ETAc:ISTRMi_uDiploma	0.0013	0.0008	1.7060	.
ETAc:ISTRMi_uMedia	0.0023	0.0009	2.4970	*
ETAc:ISTRMi_uElementare	−0.0028	0.0038	−0.7310	
I(ETAc ²):CONDMi.L	0.0002	0.0000	5.5360	***
I(ETAc ²):CONDMi.Q	0.0001	0.0001	1.8070	.
I(ETAc ²):GEOCentro	0.0000	0.0001	−0.7480	
I(ETAc ²):GEOSud/Isole	0.0001	0.0000	1.4440	
I(ETAc ²):ISTRMi_uDiploma	0.0000	0.0001	−0.1770	
I(ETAc ²):ISTRMi_uMedia	0.0000	0.0001	−0.5380	
I(ETAc ²):ISTRMi_uElementare	0.0003	0.0001	2.0430	*
ISTRMi_uDiploma:GEOCentro	−0.0009	0.0274	−0.0340	
ISTRMi_uMedia:GEOCentro	−0.0360	0.0340	−1.0610	
ISTRMi_uElementare:GEOCentro	0.0633	0.0837	0.7560	
ISTRMi_uDiploma:GEOSud/Isole	−0.0189	0.0247	−0.7650	
ISTRMi_uMedia:GEOSud/Isole	−0.0581	0.0303	−1.9160	.
ISTRMi_uElementare:GEOSud/Isole	−0.0632	0.0734	−0.8610	
GEOCentro:CONDMi.L	−0.0220	0.0239	−0.9220	
GEOSud/Isole:CONDMi.L	−0.0316	0.0202	−1.5590	
GEOCentro:CONDMi.Q	0.0393	0.0363	1.0830	
GEOSud/Isole:CONDMi.Q	0.0692	0.0293	2.3590	*
GEOCentro:CITTMiStraniera	−0.0078	0.0654	−0.1200	
GEOSud/Isole:CITTMiStraniera	0.1351	0.1016	1.3300	
ISTRMi_uDiploma:CONDMi.L	0.0459	0.0233	1.9680	*
ISTRMi_uMedia:CONDMi.L	0.0405	0.0278	1.4610	
ISTRMi_uElementare:CONDMi.L	−0.0049	0.0706	−0.0690	
ISTRMi_uDiploma:CONDMi.Q	−0.0689	0.0330	−2.0870	*
ISTRMi_uMedia:CONDMi.Q	−0.0912	0.0395	−2.3060	*
ISTRMi_uElementare:CONDMi.Q	0.0389	0.1140	0.3420	
ISTRMi_uDiploma:SESSOFemmina	0.0347	0.0215	1.6150	
ISTRMi_uMedia:SESSOFemmina	0.0726	0.0264	2.7490	**
ISTRMi_uElementare:SESSOFemmina	−0.0446	0.0631	−0.7070	

Tabella 7.6: Coefficients — idxFUN modello ridotto (mfunr).

Termine	Estimate	Std. Error	t value	Sig.
(Intercept)	0.2690	0.0261	10.2970	***
ETAc	−0.0344	0.0008	−44.7780	***
I(ETAc ²)	−0.0003	0.0001	−3.6690	***
ISTRMi_uDiploma	−0.3397	0.0242	−14.0520	***
ISTRMi_uMedia	−0.6671	0.0275	−24.2890	***
ISTRMi_uElementare	−0.8517	0.0741	−11.4970	***
GEOCentro	0.0788	0.0149	5.2840	***
GEOsud/Isole	−0.0862	0.0131	−6.5700	***
CONDMi.L	−0.0126	0.0232	−0.5430	
CONDMi.Q	0.1204	0.0282	4.2630	***
SESSOFemmina	−0.2252	0.0294	−7.6650	***
CITTMiStraniera	−0.2101	0.0349	−6.0230	***
ETAc:CONDMi.L	−0.0033	0.0006	−5.2710	***
ETAc:CONDMi.Q	0.0000	0.0018	−0.0090	
I(ETAc ²):SESSOFemmina	0.0001	0.0001	2.2670	*
I(ETAc ²):ISTRMi_uDiploma	0.0002	0.0001	2.9360	**
I(ETAc ²):ISTRMi_uMedia	0.0003	0.0001	4.1020	***
I(ETAc ²):ISTRMi_uElementare	0.0002	0.0001	1.6840	.
I(ETAc ²):CONDMi.L	0.0002	0.0000	5.1080	***
I(ETAc ²):CONDMi.Q	−0.0001	0.0001	−0.5660	
ISTRMi_uDiploma:SESSOFemmina	0.0544	0.0279	1.9470	.
ISTRMi_uMedia:SESSOFemmina	0.1206	0.0337	3.5760	***
ISTRMi_uElementare:SESSOFemmina	0.1341	0.0778	1.7240	.
CONDMi.L:SESSOFemmina	−0.0726	0.0237	−2.8040	**
CONDMi.Q:SESSOFemmina	−0.1194	0.0323	−3.6980	***

Tabella 7.7: Coefficients — idxSERIO modello ridotto (mserior).

Termine	Estimate	Std. Error	t value	Sig.
(Intercept)	0.1356	0.0229	5.9350	***
ETAc	−0.0039	0.0008	−4.7410	***
I(ETAc ²)	−0.0004	0.0001	−8.1550	***
ISTRMi_uDiploma	−0.2994	0.0249	−12.0060	***
ISTRMi_uMedia	−0.7710	0.0282	−27.3460	***
ISTRMi_uElementare	−1.1600	0.0679	−17.0920	***
GEOCentro	−0.1211	0.0162	−7.4930	***
GEOSud/Isole	−0.4242	0.0134	−31.6080	***
CONDMi.L	−0.1499	0.0231	−6.4880	***
CONDMi.Q	0.0973	0.0348	2.7940	**
SESSOFemmina	−0.0831	0.0172	−4.8260	***
CITTMiStraniera	−0.1926	0.0280	−6.8820	***
ETAc:CONDMi.L	0.0018	0.0005	3.7200	***
ETAc:CONDMi.Q	0.0006	0.0014	0.4570	
ETAc:ISTRMi_uDiploma	0.0013	0.0008	1.6410	.
ETAc:ISTRMi_uMedia	0.0023	0.0009	2.5150	*
ETAc:ISTRMi_uElementare	−0.0028	0.0038	−0.7240	
I(ETAc ²):CONDMi.L	0.0002	0.0000	5.6360	***
I(ETAc ²):CONDMi.Q	0.0001	0.0001	1.6850	.
I(ETAc ²):ISTRMi_uDiploma	0.0000	0.0001	−0.1870	
I(ETAc ²):ISTRMi_uMedia	0.0000	0.0001	−0.4660	
I(ETAc ²):ISTRMi_uElementare	0.0003	0.0001	2.1540	*
GEOCentro:CONDMi.L	−0.0282	0.0178	−1.5820	
GEOSud/Isole:CONDMi.L	−0.0241	0.0159	−1.5220	
GEOCentro:CONDMi.Q	0.0457	0.0354	1.2930	
GEOSud/Isole:CONDMi.Q	0.0704	0.0287	2.4550	*
ISTRMi_uDiploma:CONDMi.L	0.0449	0.0233	1.9290	.
ISTRMi_uMedia:CONDMi.L	0.0370	0.0277	1.3370	
ISTRMi_uElem.:CONDMi.L	−0.0090	0.0703	−0.1270	
ISTRMi_uDiploma:CONDMi.Q	−0.0666	0.0329	−2.0240	*
ISTRMi_uMedia:CONDMi.Q	−0.0843	0.0394	−2.1410	*
ISTRMi_uElem.:CONDMi.Q	0.0521	0.1136	0.4580	
ISTRMi_uDiploma:SESSO(F)	0.0348	0.0215	1.6200	
ISTRMi_uMedia:SESSO(F)	0.0740	0.0264	2.8070	**
ISTRMi_uElem.:SESSO(F)	−0.0456	0.0630	−0.7230	

7.7 Conclusioni

L'età centrata e quadratica risulta un determinante chiave, con pendenze e curvature che dipendono dal profilo di `CONDMi` e, in misura minore, da titolo e genere. Le differenze territoriali e di cittadinanza sono significative. Sul piano della bontà di adattamento, la quota di devianza spiegata è contenuta: $R^2 \approx 0.22$ per `idxFUN` e $R^2 \approx 0.17$ per `idxSERIO`, valori non elevati; ciò suggerisce che, pur cogliendo pattern sistematici, il potere esplicativo complessivo non è pienamente soddisfacente.

Capitolo 8

Conclusioni e sviluppi futuri

Sintesi dei risultati

Questo lavoro ha proposto una misurazione articolata dell'uso di Internet in Italia costruendo indici di dominio (sanitario, informativo, social, finanziario, intrattenimento) tramite analisi fattoriale su matrice poliorica e pesi normalizzati, così da riflettere in modo coerente la natura dicotomica delle variabili e le relazioni latenti tra pratiche d'uso. Tale scelta ha garantito fattori interpretabili e comparabili tra domini, evitando le assunzioni forti della correlazione di Pearson su variabili binarie. *Cfr.* risultati e tabelle dei carichi e dei pesi normalizzati.

Dalla descrizione degli indici emerge che l'ambito informativo presenta, in media, i livelli più alti, seguito dal social e dall'intrattenimento; sanità e finanza risultano meno diffusi. Gli indici di secondo livello distinguono un uso "ludico" (`idxFUN`) più sensibile all'età e un uso "utilitaristico" (`idxSERIO`) più vicino a istruzione e posizione nel mercato del lavoro; l'indice complessivo (`idxTOT`) si colloca su livelli intermedi. Le correlazioni di Spearman confermano: età fortemente associata in negativo a `idxFUN`, effetti più contenuti su `idxSERIO`; genere e cittadinanza hanno impatto minimo; si osserva un gradiente territoriale Nord/Centro vs Sud/Isole soprattutto per l'uso "serio".

La segmentazione k-means sugli indici di dominio, guidata dall'indice

di silhouette, ha indicato un massimo a $k = 2$ ma differenze modeste fino a $k = 4$; la soluzione a quattro gruppi risulta più informativa e interpretabile, con 52% di varianza tra-cluster e dimensioni dei gruppi bilanciate. I profili emersi sono: **C1** utilizzatori marginali (bassi su tutti i domini), **C2** “info-only/anti-social” (molto informativi, poco social), **C3** social & info (comunicazione e contenuti), **C4** heavy multipurpose (alti su tutti i domini). La distribuzione per età, istruzione, condizione occupazionale e territorio differenzia nettamente i cluster, mentre genere e cittadinanza non discriminano in modo rilevante.

L’analisi con Random Forest e PDP 2D conferma che *l’età* è la leva principale e interagisce con istruzione, condizione occupazionale e area geografica: alle età centrali cresce il peso dell’istruzione; gli occupati presentano livelli superiori di uso “serio”; Nord/Centro prevalgono su Sud/Isole; gli effetti di sesso e cittadinanza restano modesti.

L’analisi logistica (fractional logit) su `idxFUN` e `idxSERIO` conferma che *l’età* è la leva principale, con andamento concavo: intorno all’età media un +10 anni riduce le odds di `idxFUN` di circa il 31% e di `idxSERIO` di circa l’8%. L’effetto dell’età interagisce con `CONDMi` (pendenza più sfavorevole ai livelli bassi e concavità che si attenua ai livelli alti) e, in misura minore, con titolo di studio e sesso. Permangono forti gradienti per istruzione (vs Laurea: *Diploma* OR ≈ 0.71 , *Media* ≈ 0.51 , *Elementare* ≈ 0.43 per `idxFUN`; ≈ 0.74 , 0.46 , 0.31 per `idxSERIO`) e differenze territoriali nette (Nord/Centro prevalgono su Sud/Isole, con segno del Centro che varia tra gli esiti). Gli effetti di sesso e cittadinanza restano complessivamente modesti, pur ampliandosi in alcune combinazioni (es. `SESSO` $\times$ `CONDMi`). Il quasi-saturo migliora marginalmente il fit ma mette in luce eterogeneità di dettaglio utile alla discussione (cfr. Tab. 7.2–7.9).

Implicazioni e possibili soluzioni adottabili

Le evidenze suggeriscono politiche e interventi mirati lungo tre assi:

1. **Competenze e accompagnamento per fasce anziane.** Programmi di alfabetizzazione digitale con tutoraggio intergenerazionale;

2. **Riduzione del divario territoriale e di condizione.** Co-progettazione di servizi digitali con comuni e PA locali (SPID, app PA, prenotazioni sanitarie) e formazione in contesti di lavoro/centri per l'impiego, per sostenere l'uso utilitaristico dove è più carente.
3. **Design inclusivo dei servizi.** Interfacce semplificate, canali ibridi (digitale+assistenza fisica), percorsi guidati per trasformare utenti "marginali" o "info-only" in *multipurpose* evitando barriere di usabilità. I cluster individuati offrono target chiari.

Sul piano metodologico, si raccomanda di usare con cautela le sintesi di secondo/terzo livello quando la varianza spiegata è limitata o alcuni domini (es. social) hanno bassa capacità discriminante, affiancando sempre letture per dominio.

Criticità incontrate

Durante lo studio sono emerse alcune criticità:

- **Disomogeneità del questionario AVQ nel tempo.** Le modifiche di contenuto e codifica tra annualità rendono complessi i confronti di lungo periodo e hanno orientato l'analisi sulle sole edizioni recenti con ricodifiche manuali.
- **Filtro sugli utenti attivi.** Per misurare il *secondary digital divide* si è condizionato ai rispondenti con uso di Internet negli ultimi 3 mesi, allineando la finestra temporale delle domande d'uso.
- **Instabilità dovuta a variabili quasi costanti.** È stata rilevata una variabile quasi sempre pari a 1 che induceva instabilità nelle stime su matrice poliorica; si è optato per l'esclusione per evitare distorsioni e scarsa capacità discriminante.
- **Segmentazione.** La soluzione a $k = 4$ privilegia l'interpretabilità a fronte di una silhouette leggermente inferiore al massimo; ciò richiede prudenza nell'uso predittivo dei cluster.

Suggerimenti per future rilevazioni e sviluppi

Alla luce dei limiti riscontrati e dei risultati ottenuti, si propone:

1. **Maggiore armonizzazione longitudinale AVQ.** Stabilizzare nuclei di domande e codifiche uguali per consentire serie comparabili;
2. **Misure di intensità e competenza.** Integrare alla dicotomia usa/non usa frequenze, difficoltà percepite, autonomia e indicatori di esito (terzo livello) per valutare benefici percepiti dagli intervistati.
3. **Dettaglio territoriale e campionamento.** Oversampling di anziani e bassa istruzione in aree a bassa offerta di servizi; indicatori di contesto (urbano/rurale, dotazione locale di sportelli e servizi digitali).
4. **Integrazione dati.** Linkage (nel rispetto della privacy) con fonti amministrative su credenziali e servizi digitali (es. utilizzi SPID/servizi PA) per validare gli indici d'uso "serio".
5. **Sviluppi analitici.** Estendere lo studio a dati panel e valutare metriche alternative e robuste di clustering.
6. **Fasce d'età definite in analisi, non alla fonte.** Invece di imporre classi d'età prefissate in fase di rilascio, si suggerisce di fornire l'età in anni e lasciare all'analista la costruzione delle fasce. Ciò migliora la comparabilità longitudinale, consente divisioni in classi alternative e modelli flessibili senza perdita di informazione.

In conclusione, la lettura congiunta di indici, cluster e RF mostra un *digital divide* fortemente generazionale e modulato da istruzione, lavoro e territorio. Gli esiti forniscono mappe operative per azioni mirate e delineano una chiara agenda di miglioramento delle misure ufficiali, a beneficio di ricercatori e policy maker.

Bibliografia

- ISTAT (2025). *Aspetti della vita quotidiana (AVQ). Documentazione e microdati*. Istituto Nazionale di Statistica.
- Kleinrock, Leonard (2019). *ARPANET and the Origins of the Internet*. MIT Press.
- Telecom Italia (2000). *TIN.it, tariffe flat e prime linee ADSL in Italia*. Telecom Italia.
- Wired (1996). “L’arrivo di Internet in Italia e l’esperienza Video On Line”. In: *Wired Italia*.